**Universidad de Alicante**

Grado en Ingeniería Informática y Administración y Dirección de Empresas

Trabajo de Fin de Grado

# Optimización dinámica de carteras mediante aprendizaje por refuerzo profundo con contexto exógeno y control adaptativo del riesgo

Autora: Lidia Montero García

Tutor: Higinio Mora Mora

Curso 2025–2026

## Resumen

Este trabajo explora la gestión adaptativa de inversiones usando una arquitectura basada en aprendizaje por refuerzo. Un agente, configurado con PPO (*Proximal Policy Optimization*), toma decisiones sobre distribución de capital tras analizar datos del mercado combinados con señales macroeconómicas externas. Más allá del algoritmo principal, el sistema incorpora elementos de control para que las decisiones de cartera no dependan solo de la rentabilidad esperada, sino también del riesgo, estabilidad y las reglas básicas que debe cumplir la cartera. La evaluación se realiza mediante un esquema *walk-forward*, organizado en bloques temporales consecutivos, lo que permite analizar el comportamiento del modelo en distintos periodos de mercado respetando el orden temporal de los datos. Además, se compara frente a métodos tradicionales: la cartera equiponderada (*Equal Weight*), la ponderación inversa a la volatilidad (*Inverse Volatility*), la cartera de mínima varianza (*Minimum Variance*) y la optimización media-varianza (*Mean-Variance*) y *Buy and Hold*.

La propuesta no se limita a añadir contexto externo como una variable más en el estado observado por el agente, sino que se plantea un proceso de decisión más estructurado. El agente combina señales del mercado, variables macro financieras y señales de régimen y, con esto, se utiliza un mecanismo de *gating* para regular la importancia del contexto externo antes de tomar la decisión de ajuste en la cartera. Con ello, el sistema busca que la asignación de activos no dependa únicamente de la información interna del mercado, sino también de una lectura más amplia del entorno financiero. De esta forma, el trabajo analiza si este tipo de arquitectura puede aportar valor frente a estrategias clásicas de referencia en términos de rentabilidad, riesgo y estabilidad operativa.

**Palabras clave:** aprendizaje por refuerzo profundo, optimización de carteras, PPO, contexto exógeno, mecanismo de *gating*, capa de seguridad convexa, validación *walk-forward.*

Códigos UNESCO: 1203.17 – Informática; 1203.04 – Inteligencia Artificial; 5311.02 – Gestión financiera; 5311.07 – Investigación operativa.

## Abstract

*This Bachelor's Thesis explores adaptive investment management through an architecture based on reinforcement learning. An agent configured with PPO (Proximal Policy Optimization) makes capital allocation decisions by analyzing market data combined with external macroeconomic signals. Beyond the main algorithm, the system incorporates control elements so that portfolio decisions do not depend only on expected return, but also on risk, stability, and the basic rules that the portfolio must satisfy. The evaluation is carried out using a walk-forward scheme, organized into consecutive time blocks, which makes it possible to analyze the behavior of the model across different market periods while preserving the temporal order of the data. In addition, the model is compared with traditional strategies such as Equal Weight, Inverse Volatility, Minimum Variance, Mean-Variance, and Buy and Hold.*

*The proposal does not simply add external context as another variable in the state observed by the agent, but instead defines a more structured decision-making process. The agent combines market signals, macro-financial variables, and regime signals, and uses a gating mechanism to regulate the importance of the external context before deciding the portfolio adjustments. In this way, the system seeks to ensure that asset allocation does not depend only on internal market information, but also on a broader reading of the financial environment. Therefore, this work analyzes whether this type of architecture can provide value compared with classical benchmark strategies in terms of return, risk, and operational stability.*

***Keywords:*** *deep reinforcement learning, portfolio optimization, PPO, exogenous context, gating mechanism, convex safety layer, walk-forward validation.*

# Índice

Resumen ..... i
Abstract ..... ii
Índice ..... 3
Índice de Figuras ..... 5
Índice de Tablas ..... 6
Capítulo 1. Introducción ..... 7
1.1 Motivación y justificación ..... 7
1.2 Objetivos ..... 8
1.3 Metodología ..... 10
1.3.1 Enfoque metodológico y planteamiento general ..... 10
1.3.2 Diseño del modelo y procedimiento experimental ..... 10
1.3.3 Entrenamiento, validación temporal y evaluación ..... 11
1.3.4 Tecnologías utilizadas ..... 13
1.4 Estructura del documento ..... 14
Capítulo 2. Marco Teórico ..... 15
2.1 Fundamentos matemáticos de la asignación de carteras ..... 15
2.2 Modelos clásicos de referencia ..... 17
2.3 Riesgo, fricciones operativas y métricas de evaluación ..... 18
2.4 Formulación secuencial del problema de cartera ..... 21
2.5 Aprendizaje por refuerzo profundo y algoritmo PPO ..... 23
2.6 Restricciones, conjunto factible y proyección convexa ..... 24
Capítulo 3. Estado del arte ..... 27
3.1 Optimización clásica de carteras y transición hacia decisiones dinámicas ..... 27
3.2 Aprendizaje profundo y representación del estado en gestión de carteras ..... 28
3.3 Estrategias de evaluación ..... 34
3.4 Síntesis del estado del arte y hueco de investigación ..... 35
Capítulo 4. Propuesta del modelo, arquitectura y solución ..... 37
4.1 Visión general y esquema del sistema propuesto ..... 37
4.2 Datos, universo de activos y construcción del estado ..... 38
4.3 Arquitectura de representación y modulación contextual ..... 40
4.4 Política PPO y acción incremental ..... 43
4.5 Control operativo y ejecución segura ..... 44
4.6 Función de recompensa ..... 46
4.7 Configuración final del modelo ..... 48
Capítulo 5. Experimentación, resultados y discusión ..... 49
5.1 Configuración de la evaluación ..... 49

5.2 Métricas utilizadas ..... 50
5.3 Resultados globales ..... 51
5.4 Resultados por ventanas temporales ..... 54
5.4.1 Escenarios favorables ..... 57
5.4.2 Escenarios desfavorables ..... 60
5.5 Discusión de los resultados ..... 62
Capítulo 6. Conclusiones y trabajo futuro ..... 65
6.1 Conclusiones ..... 65
6.2 Limitaciones ..... 65
6.3 Trabajo futuro ..... 66
Bibliografía ..... 68

# Índice de Figuras

Figura 1.1. Esquema simplificado del sistema propuesto. Elaboración propia.

Figura 2.1. Esquema de la capa de seguridad convexa y su integración en el flujo de decisión del agente. Elaboración propia.

Figura 4.1. Arquitectura general del sistema propuesto, desde la construcción del estado observado hasta la ejecución final de la cartera bajo control operativo y restricciones de factibilidad. Elaboración propia.

Figura 4.2. Descomposición conceptual del estado observado en bloques de mercado, estado heredado de la cartera y contexto exógeno. Elaboración propia.

Figura 4.3. Esquema de la arquitectura de representación y modulación contextual del modelo propuesto. Elaboración propia.

# Índice de Tablas

Tabla 2.1. Modelos clásicos de referencia y criterio de asignación. Elaboración propia.

Tabla 2.2. Definición de las principales magnitudes operativas utilizadas en el sistema y de las métricas empleadas para evaluar su comportamiento. Elaboración propia.

Tabla 3.1. Principales arquitecturas de representación utilizadas en aprendizaje profundo aplicado a carteras. Elaboración propia.

Tabla 4.1. Componentes de la función de recompensa del modelo propuesto. Elaboración propia.

Tabla 5.1. Resumen de la configuración experimental utilizada en la evaluación. Elaboración propia a partir de la configuración del proyecto.

Tabla 5.2. Interpretación de las métricas utilizadas en la evaluación. Elaboración propia.

Tabla 5.3. Resultados globales de las estrategias evaluadas. Elaboración propia.

Tabla 5.4. Resultados del modelo PPO_gated_full en las trece ventanas temporales de prueba del procedimiento *walk-forward*. Elaboración propia.

Tabla 5.5. Comparación de estrategias en el *fold* 5, correspondiente al periodo 2020-06 a 2021-06. Elaboración propia.

Tabla 5.6. Comparación de estrategias en el *fold* 12, correspondiente al periodo 2023-12 a 2024-12. Elaboración propia.

Tabla 5.7. Comparación de estrategias en el *fold* 6, correspondiente al periodo 2020-12 a 2021-12. Elaboración propia.

Tabla 5.8. Comparación de estrategias en el *fold* 3, correspondiente al periodo 2019-06 a 2020-06. Elaboración propia.

Tabla 5.9. Comparación de estrategias en el *fold* 4, correspondiente al periodo 2019-12 a 2020-12. Elaboración propia.

Tabla 5.10. Comparación de estrategias en el *fold* 7, correspondiente al periodo 2021-06 a 2022-06. Elaboración propia.

# Capítulo 1. Introducción

## 1.1 Motivación y justificación

En finanzas cuantitativas, una parte fundamental es decidir cómo construir una cartera y repartir el capital entre distintos activos. Normalmente, se busca obtener la máxima rentabilidad sin asumir un riesgo excesivo, aunque en algunos casos se da más importancia a la estabilidad de la cartera y al control de sus variaciones a lo largo del tiempo. Para resolver estas cuestiones, los métodos tradicionales han dominado durante décadas. Entre ellos, el modelo de Markowitz, centrado en media-varianza, ha sido fundamental para muchos enfoques posteriores. La idea del modelo de Markowitz es elegir una combinación de activos que ofrezca la mejor relación posible entre lo que se espera ganar y la variabilidad que está dispuesto a asumir.

Aunque los métodos clásicos son importantes, aplicar estas técnicas en entornos reales implica dificultades. Debido al constante cambio del comportamiento de los mercados financieros, aparecen periodos donde la inestabilidad aumenta o disminuye. Además, cambios en contextos macro financieros afectan sus patrones. Junto a ello, situaciones de tensión transforman cómo responden los activos. En estas situaciones, las estimaciones de retornos esperados y covarianzas pueden depender mucho del periodo histórico utilizado. Como consecuencia, la cartera puede volverse poco estable. A pesar de ello, los métodos tradicionales conservan su valor, pero surge la necesidad de explorar otras alternativas que sean capaces de responder con mayor flexibilidad ante entornos cambiantes.

Hoy, gracias a los avances en inteligencia artificial, surgen maneras diferentes de manejar inversiones, más rápidas y adaptables. A diferencia de las fórmulas clásicas, estas estrategias detectan tendencias sin atenerse a reglas fijas, modificando su comportamiento conforme evolucionan las condiciones. En este contexto, la inversión puede entenderse como un proceso donde el agente observa el mercado, decide cómo ajustar la cartera y aprende a partir del resultado obtenido. Dentro de esta línea, el interés de este estudio va más allá de usar simplemente aprendizaje por refuerzo en decisiones de inversión, ya que busca explorar una estructura más amplia frente a otros modelos que solo miran valores del mercado. No solo importan los precios, rendimientos o datos técnicos; también se contemplan factores macroeconómicos junto con situaciones de estrés influyen en los mercados. Este trabajo introduce un sistema usando PPO (*Proximal Policy Optimization*), propuesto por Schulman et al. (2017). Es un algoritmo de aprendizaje por refuerzo profundo que ayuda al agente a aprender qué decisiones puede tomar de una forma progresiva según su interacción con un entorno.

Sin embargo, añadir más datos no siempre hace al sistema mejor, porque lo útil que resulte el entorno exterior depende del momento y de cómo esté el mercado. En ciertos momentos, esta información puede introducir ruido si se utiliza todo con la misma importancia. Partiendo de ahí, esta propuesta no solo incluye un contexto financiero

general, sino que también busca controlar cuánto peso debe tener en cada momento. Al mismo tiempo, integra una función protectora para asegurar que las reglas se respeten y los pesos de la cartera respeten las restricciones definidas. Así, el enfoque busca no solo generar estrategias flexibles, sino examinar una forma más ordenada y consistente de actuar durante su ejecución.

Examinar un camino distinto frente a los métodos tradicionales para componer carteras financieras puede ser útil. Este planteamiento surge como respuesta a ciertas limitaciones observadas en las técnicas convencionales. En lugar de seguir esquemas fijos, se explora otra vía posible. Esta opción busca ofrecer perspectivas adicionales al momento de tomar decisiones de inversión. Su inclusión permite revisar opciones que normalmente quedan fuera del debate principal. Los métodos tradicionales siguen siendo referencias fundamentales y continúan siendo competitivos en muchos contextos, por lo que el interés del trabajo consiste en estudiar, de forma comparativa y rigurosa, si una formulación basada en aprendizaje por refuerzo profundo puede aportar valor al combinar información de mercado, contexto exógeno y mecanismos explícitos de control.

## 1.2 Objetivos

El objetivo de este trabajo es diseñar, implementar y evaluar un sistema de optimización dinámica de carteras basado en el aprendizaje por refuerzo profundo. Se utiliza para ello un agente entrenado con PPO para aprender una política que sea capaz de ajustar la distribución de activos en el tiempo. El objetivo del trabajo no solo es obtener rentabilidad, sino también analizar la estabilidad de las decisiones, el riesgo asumido y el comportamiento del sistema en distintos periodos. Por eso la propuesta combina información bursátil con señales externas del entorno e incorpora mecanismos de control tendentes a evitar decisiones excesivamente inestables.

Este estudio busca alcanzar los siguientes hitos:

- Diseñar un entorno de aprendizaje por refuerzo adaptado al problema de asignación de activos en cartera: Se definirá un estado que integra datos del mercado, ponderaciones anteriores de la cartera junto con factores macro financieros externos.
- Entrenar un agente PPO que aprenda una política de asignación eficiente al problema que se plantea: El agente operará con pasos secuenciales, donde observa los datos presentes de cada fase mientras sugiere cambios en la composición de la cartera. Su propósito consiste en adaptar de forma progresiva cómo se reparten los activos, considerando la evolución del mercado y el resultado de sus decisiones previas.
- Incorporar un mecanismo de *gating* para modular la relevancia del contexto exógeno: El *gating* es un mecanismo de modulación aprendido que sirve para controlar cuánto influye una variable, en este caso es el contexto macro financiero,

sobre la información final del modelo. Es el filtro mencionado que ayudará al modelo a decidir cuánto peso deberá tener la información externa en cada periodo.

- Integrar una capa de control operativo y de seguridad sobre las decisiones del agente: Uno de los objetivos que se plantea con el sistema es limitar cambios demasiado bruscos en la cartera. Es importante considerar no solo la rentabilidad, sino también la estabilidad y coherencia dentro de la estrategia de inversión.
- Definir una función de recompensa que se alinee con el comportamiento financiero que se plantea: Dentro de buscar una estabilidad dentro de la cartera, se implementa un sistema de recompensas que no solo se centra en la rentabilidad obtenida, también se tiene en cuenta las pérdidas, el riesgo y la rotación. De esta manera, la penalización de estos elementos contribuye a que el agente tome decisiones más equilibradas.
- Examinar el comportamiento del modelo mediante validación *walk-forward*: Esta validación consiste en entrenar y evaluar al modelo respetando un orden temporal de los datos. Se busca que el modelo avance por los distintos periodos históricos y con ello comprobar cómo actúa el sistema en diferentes momentos de mercado, evitando sacar conclusiones de un único tramo temporal.
- Comparar el modelo propuesto con estrategias clásicas: Se contrasta el resultado del modelo frente a *baselines* clásicos de inversión, como *Equal Weight, Inverse Volatility, Minimum Variance, Mean-Variance* y *Buy and Hold*. Se pretende comprobar si esta propuesta puede aportar valor y competir con estrategias simples y consolidadas, que siguen criterios fijos frente a un sistema que ajusta de forma dinámica la cartera.
- Analizar cómo los cambios del entorno afectan al comportamiento del modelo: Se estudia de qué manera distintas condiciones de mercado y del contexto macro financiero influyen en las decisiones del agente, en su estabilidad operativa y en su rendimiento ajustado al riesgo, con el fin de evaluar si la arquitectura propuesta responde de forma diferente según el entorno observado.

## 1.3 Metodología

### 1.3.1 Enfoque metodológico y planteamiento general

Este estudio usa una combinación de dos métodos. Por un lado, parte de unas preguntas de investigación que se contrastarán mediante el experimento; por otro, el proceso de diseño, prueba y evaluación del proyecto. No se busca únicamente aplicar una herramienta, sino analizar cómo las decisiones que se emplean en el diseño influyen en el sistema de optimización de carteras con las condiciones reales del mercado.

Desde la parte de investigación, el trabajo parte de la idea de que la asignación dinámica de carteras puede beneficiarse del uso del contexto macro financiero, siempre que este contexto se integre de una forma selectiva y bajo mecanismos de control que eviten decisiones inestables. A partir de este planteamiento, el presente proyecto formula, implementa y, por último, contrasta experimentalmente una arquitectura basada en aprendizaje por refuerzo profundo, enriquecida con un mecanismo de *gating*, restricciones operativas y una capa de seguridad convexa.

El desarrollo del trabajo queda guiado por las siguientes preguntas de investigación:

- si la incorporación de contexto exógeno macro financiero aporta información útil para la optimización dinámica de carteras más allá de las variables de mercado;
- si la incorporación de un mecanismo de *gating* permite integrar el contexto exógeno de forma más controlada dentro de la arquitectura del modelo;
- si la incorporación de mecanismos de disciplina operativa y de una capa de seguridad mejora la estabilidad fuera de muestra, el control del riesgo y la robustez del sistema frente a cambios en el régimen de mercado.

A partir de estas preguntas, la metodología se divide en tres fases principales: se presenta a continuación el diseño e implementación del modelo. Más adelante, se describe el proceso del entrenamiento y evaluación, incluyendo la validación temporal y la comparación con las estrategias clásicas. Por último, se presentan las tecnologías utilizadas en todo el proceso para desarrollar el sistema.

### 1.3.2 Diseño del modelo y procedimiento experimental

El sistema propuesto se formula como un modelo de decisión secuencial. En cada instante, el agente observa un estado de contexto exógeno, información del mercado y pesos previos de cartera. Tras esto, se determina una decisión de rebalanceo que define la nueva asignación de capital. Esta forma de plantear el sistema permite entender el proceso como una inversión dinámica, donde cada decisión depende tanto de la situación actual del mercado como del entorno financiero de ese periodo.

El agente es entrenado usando PPO, dado que es un algoritmo que resulta adecuado en contextos de aprendizaje por refuerzo y opera bien en espacios continuos, es decir, en las decisiones continuas de la asignación de pesos de una cartera. En lugar de generar una

cartera nueva en cada paso, aprende a proponer ajustes sobre la cartera anterior. En la práctica, este proceso resulta útil y coherente porque la decisión de inversión no consiste en reconstruir desde cero una cartera, sino en modificar una posición ya existente.

El diseño del modelo integra datos bursátiles junto con factores externos financieros. La información de mercado representa el comportamiento de los activos, mientras que el contexto macro financiero aporta una visión más amplia de las condiciones del entorno. Este contexto exógeno aporta valor porque algunos cambios relevantes del mercado no siempre están reflejados en los precios o rendimientos de cada activo.

En la fase final del modelo, el sistema aplica controles operativos y de seguridad para mantener unas restricciones básicas de las asignaciones de cartera. Es decir, que la suma de los pesos de la cartera sea igual al capital disponible, garantizar que los pesos sean válidos y que ningún activo supere el límite establecido. Gracias a esto, la decisión del agente pasa por una revisión que hace que sea más estable y coherente desde el punto de vista práctico.

De esta forma, el diseño del modelo queda organizado en tres partes: la observación del estado, la decisión de rebalanceo mediante el algoritmo PPO y la revisión final de la cartera mediante los controles operativos.

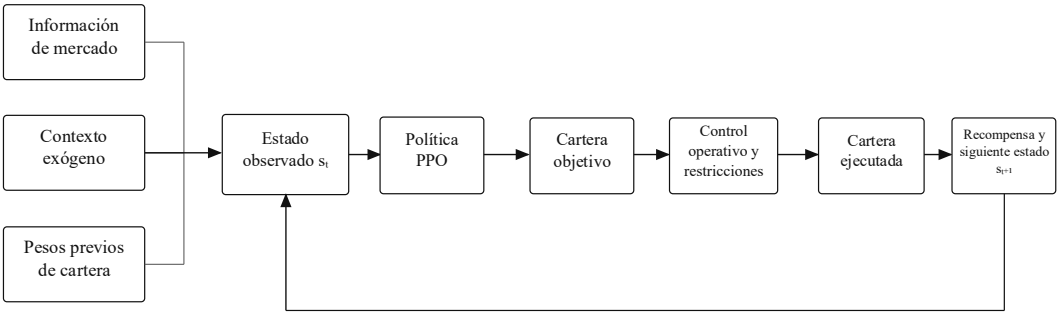



***Figura 1.1.*** *Esquema simplificado del sistema propuesto. Elaboración propia.*

### 1.3.3 Entrenamiento, validación temporal y evaluación

Como he mencionado anteriormente, en lugar de realizar una división de datos al azar, se trabaja con series financieras ordenadas en el tiempo. De esta manera, se entrena y prueba el sistema con una validación temporal como *walk-forward*. Así se simula mejor cómo funcionaría el modelo si se usara paso a paso en operaciones reales. A diferencia de métodos fijos, esta estrategia evalúa el desempeño bajo distintas condiciones del

mercado. Gracias a ella, las etapas de ajuste, revisión y prueba mantienen su secuencia lógica en el tiempo.

En cada iteración se reorganiza el conjunto de datos con bloques consecutivos: cuatro años para ajustar el modelo, seguidos de un año de comprobación y otro de evaluación final, desplazando la ventana seis meses en cada paso. Gracias a este esquema, los modelos pasan por etapas de crecimiento, crisis marcadas o repuntes posteriores, lo que permite observar cómo responden sin depender solo de condiciones favorables. Por ejemplo, si una partición utiliza los años 2010-2013 para entrenamiento, 2014 para validación y 2015 para prueba, la siguiente empezaría seis meses más tarde y repetiría el mismo esquema con los periodos desplazados.

La elección de estos periodos es una decisión experimental propia, pero coherente con esquemas *walk-forward* empleados en evaluación financiera, donde es habitual utilizar varios años de entrenamiento y periodos posteriores fuera de muestra para validar el modelo respetando la secuencia temporal (López de Prado, 2018). Además, existen trabajos con estructuras parecidas: Stanciu (2022) emplea validación *walk-forward* con cuatro años de entrenamiento y un año de prueba, mientras que Mantshimuli (2026) utiliza ventanas temporales secuenciales con cuatro años de entrenamiento, un año de validación y un año de prueba. Por lo tanto, en este trabajo la organización temporal no pretende ser una regla universal de entrenamiento, pero sí que sigue una lógica habitual en evaluación financiera con ventanas móviles. Los cuatro años de entrenamiento ofrecen suficientes observaciones diarias para ajustar el agente, el año de validación permite seleccionar la configuración sin usar la prueba y el año final proporciona una evaluación interpretable.

El bloque de validación sirve para escoger la configuración ya entrenada antes de hacer la prueba final. Indicadores para medir la relación entre rentabilidad y riesgo son los que se utilizan para realizar esta elección, como el ratio de Sharpe y el ratio de Calmar. La idea principal es evitar quedarse con un modelo que tenga una rentabilidad alta en un tramo concreto, pero que asuma caídas excesivas o muestre un comportamiento demasiado inestable.

En la evaluación final, los resultados se comparan con estrategias clásicas consolidadas. Todas estas estrategias son evaluadas y comparadas sobre las mismas ventanas temporales, lo que permite observar cómo responde cada método en distintos escenarios, como periodos alcistas, momentos de crisis o etapas de recuperación. La comparación se realiza mediante métricas como la rentabilidad anualizada, el ratio de Sharpe, la máxima caída acumulada, la rotación de cartera y los costes de transacción. Estos indicadores no solo ayudan a comparar la rentabilidad, sino también el riesgo, la estabilidad e intensidad de los cambios realizados dentro de la cartera.

### 1.3.4 Tecnologías utilizadas

Todo el desarrollo del proyecto ha sido realizado en Python, haciendo uso de herramientas específicas para procesar información numérica. Para organizar y transformar los datos se han empleado librerías como pandas, NumPy y scikit-learn. Con yfinance, resulta posible recuperar valores históricos de mercados, junto con volúmenes operados y referencias comparativas estandarizadas. Por otro lado, fredapi combinado con pandas-datareader permiten acceder a secuencias temporales económicas oficiales.

La parte de aprendizaje por refuerzo se implementa con Stable-Baselines3 (Raffin et al., 2021) sobre Gymnasium, utilizando PyTorch como backend de aprendizaje profundo (Paszke et al., 2019). El detector explícito de régimen se apoya en herramientas estadísticas de scikit-learn (Pedregosa et al., 2011), mientras que la capa de seguridad basada en proyección convexa y restricciones operativas se formula mediante CVXPY (Diamond & Boyd, 2016) y se resuelve con el solver OSQP (Stellato et al., 2020).

Durante la ejecución, los entrenamientos generan registros que permiten hacer seguimiento a cada prueba y pueden ser compatibles con TensorBoard, lo que permite estar observando continuamente sin tener que hacer ninguna intervención manual adicional. La organización general del entorno está definida en archivos en formato YAML, lo cual permite hacer un control preciso sobre las distintas iteraciones que se van haciendo en tiempo real. Otra capa incluye el uso de formatos específicos pensados para mantener intacta la línea temporal de los datos. Parquet se utiliza como opción principal para información cruda. En cuanto a indicadores finales por bloque, los conjuntos de tipo CSV registran valores clave sin pérdida estructural. Cada archivo YAML también actúa como guía de referencia al documentar decisiones operativas puntuales.

## 1.4 Estructura del documento

Para facilitar la lectura, el trabajo se ha organizado de forma progresiva, desde la contextualización del problema hasta el análisis final de los resultados.

El Capítulo 1 introduce el proyecto, explica la motivación del tema, define los objetivos y describe la metodología seguida durante el desarrollo del trabajo.

El Capítulo 2 presenta el marco teórico necesario para entender el problema abordado y las herramientas conceptuales sobre las que se apoya la propuesta.

El Capítulo 3 revisa el estado del arte y sitúa la propuesta dentro del contexto actual de la investigación en optimización de carteras y aprendizaje por refuerzo.

El Capítulo 4 desarrolla la arquitectura del modelo planteado, detallando sus componentes principales, la lógica de decisión y los mecanismos de control y seguridad incorporados.

El Capítulo 5 recoge la parte experimental, donde se evalúan las variantes del sistema y se analizan sus resultados desde una perspectiva comparativa.

El Capítulo 6 expone las conclusiones del trabajo y plantea posibles líneas de mejora y continuidad.

Por último, se incluye la bibliografía con las referencias empleadas en la elaboración del estudio.

# Capítulo 2. Marco Teórico

## 2.1 Fundamentos matemáticos de la asignación de carteras

La asignación de carteras consiste en repartir un capital entre distintos activos financieros y que esta combinación resultante tenga una relación adecuada entre rentabilidad y riesgo. En cada instante temporal *t*, la cartera se representa como un vector de pesos $w_t \in \mathbb{R}^N$, donde cada componente $w_{i,t}$ indica la proporción del capital invertido en el activo *i.* Por ejemplo, si un peso es de 0.10, indica que el 10% del capital está invertido en ese activo. En este trabajo, el instante *t* se corresponde con un día del calendario de mercado, ya que los datos tienen frecuencia diaria. De esta manera, la cartera queda descrita por la distribución de sus pesos diariamente y por cómo cambian posteriormente los precios de los activos que la componen.

Para medir la variación de valor de cada activo entre dos periodos consecutivos de tiempo se utiliza el retorno simple. Si $Pi, t$ representa el precio ajustado del activo *i* en el día *t,* el retorno entre ese día y el siguiente se calcula con la siguiente fórmula:

$$r_{i,t+1} = \frac{P_{i,t+1} - P_{i,t}}{P_{i,t}} \tag{2.1}$$

Como se ha mencionado, esta fórmula representa la variación relativa del precio. En este caso, si el precio del activo sube, el retorno es positivo; si baja, el retorno es negativo. Es un indicador que permite comparar el comportamiento de distintos activos, aunque sus precios estén en niveles diferentes.

Una vez definido el retorno de cada activo, el rendimiento de la cartera se obtiene a partir de la combinación de esos retornos según el peso asignado a cada uno. Esto significa que no todos los activos influyen en el resultado final por igual, sino depende de la proporción invertida en ellos. Si los retornos de todos los activos entre *t* y *t+1* se agrupan en el vector $r_{t+1}$, el retorno bruto se puede expresar mediante la fórmula (2.2).

$$R_{p,t+1} = w_t^{\top} r_{t+1} = \sum_{i=1}^{N} w_{i,t}\, r_{i,t+1} \tag{2.2}$$

Esta fórmula representa que el resultado de la cartera se obtiene sumando la aportación de cada activo. Depende de dos elementos: el peso que tenía el activo en la cartera y el retorno que obtiene en el periodo siguiente. Si un activo tiene mucho peso, su subida o bajada afecta más al resultado final.

Además del retorno observado en un periodo concreto, muchos modelos de cartera trabajan con una estimación del retorno esperado. Es una magnitud que representa una previsión media del rendimiento que podrían ofrecer los activos a partir de la información disponible. Este planteamiento es uno de los pilares del enfoque media-varianza de Markowitz, donde la estrategia se analiza a partir de la relación entre rentabilidad esperada y riesgo. Si μ representa el vector de retornos esperados de los activos, el retorno

esperado de la cartera se calcula con la ponderación de esos retornos por los pesos asignados a cada activo.

$$\mathbb{E}[r_p] = w^\top \mu \tag{2.3}$$

Esta expresión muestra que la rentabilidad esperada de una cartera no depende solo de los activos que incluye, sino del capital que asigna a cada uno. Esto explica por qué dos carteras con los mismos activos pueden tener una rentabilidad esperada distinta si se reparte el capital de manera diferente.

Además de la rentabilidad esperada, una cartera también debe analizarse desde el punto de vista del riesgo. Se asocia a la variabilidad de rendimiento, es decir, a cuánto se pueden desviar los resultados respecto a su comportamiento medio. Para medirlo, es necesario tener en cuenta la volatilidad individual de cada activo y cómo se mueven entre sí. Por ello, se utiliza la matriz de covarianzas Σ, que recoge la variabilidad de cada activo y la relación entre sus movimientos. La varianza de la cartera se define como:

$$\sigma_p^2 = w^\top \Sigma w \tag{2.4}$$

La varianza mide el riesgo teniendo en cuenta la combinación de pesos y la relación entre activos. Además, a partir de esta fórmula, la volatilidad de cartera se obtiene con la raíz cuadrada de la varianza.

$$\sigma_p = \sqrt{w^\top \Sigma w} \tag{2.5}$$

Es una medida que permite expresar el riesgo en las mismas unidades que los retornos, por lo que facilita su interpretación. En conclusión, una cartera con mayor volatilidad suele tener mayores variaciones en su rendimiento, mientras que una con menor volatilidad, en principio, tiende a ser más estable.

A partir de calcular la rentabilidad y el riesgo, también se debe tener en cuenta que la cartera tiene que cumplir unas restricciones mínimas para que la asignación sea coherente. En este trabajo se considera una cartera formada únicamente por posiciones largas, es decir, sin ventas en corto y completamente invertida, lo que implica que todo el capital disponible se reparte entre todos los activos seleccionados. Por tanto, no se permiten pesos negativos y la suma de todos los pesos debe ser igual al total de capital disponible. Se representa mediante las siguientes restricciones:

$$\sum_{i=1}^{N} w_i = 1, w_i \geq 0, \quad i = 1, \dots, N \tag{2.6}$$

$$w_i \geq 0, \quad i = 1, \dots, N \tag{2.7}$$

La primera restricción (2.6) indica que la suma de todos los pesos tiene que ser igual a 1. La siguiente, recogida en (2.7), garantiza que ningún activo tenga un peso negativo.

Además de las restricciones anteriores, se puede fijar un límite de peso máximo para evitar que la cartera quede demasiado concentrada en una sola posición. Es importante, ya que asignar demasiado capital a un activo, aumenta la dependencia de la cartera

respecto al activo. Por ello, se define un peso máximo permitido $w_{\max}$, de forma que ningún activo supere ese límite:

$$w_i \leq w_{\max}, i = 1, \dots, N \tag{2.8}$$

En conjunto, estas restricciones forman el conjunto básico de carteras válidas dentro del trabajo. Esta idea es importante, ya que el modelo propuesto incorpora una capa de seguridad encargada de garantizar que la asignación cumpla estas condiciones.

## 2.2 Modelos clásicos de referencia

Una vez definida la formulación básica de una cartera, se presentan los modelos clásicos que se utilizarán como referencia comparativa con el modelo. Estos modelos no forman parte de la propuesta desarrollada, pero permiten evaluar si el sistema de aprendizaje por refuerzo aporta valor frente a estas estrategias.

La primera referencia es la cartera equiponderada, también conocida como *Equal Weight.* Esta estrategia reparte el capital por igual entre todos los activos. Su principal ventaja es que es muy sencilla de utilizar, ya que no necesita estimar retornos esperados ni matrices de covarianzas. A pesar de esta sencillez, suele obtener resultados competitivos fuera de muestra, por lo que es una referencia exigente para valorar. Si $N$ representa el número total de activos, el peso de cada uno se calcula como:

$$w_i = \frac{1}{N}, \qquad i = 1, \dots, N \tag{2.9}$$

La segunda referencia es la ponderación inversa a la volatilidad (*Inverse Volatility*). Esta estrategia asigna más peso a los activos que han mostrado menor volatilidad y menos peso a los activos más volátiles. Es una estrategia sencilla de control del riesgo, sin necesidad de estimar retornos esperados. Si $\sigma_i$ representa la volatilidad estimada del activo $i$, el peso asignado a cada activo se obtiene de forma proporcional a la inversa de su volatilidad:

$$w_i = \frac{1/\sigma_i}{\sum_{j=1}^{N} 1/\sigma_j}, i = 1, \dots, N \tag{2.10}$$

La tercera referencia es la cartera de mínima varianza (*Minimum Variance*). Esta estrategia, a diferencia de las anteriores, sí que utiliza la matriz de covarianzas para buscar la combinación adecuada de pesos que minimiza el riesgo total de la cartera. Su objetivo no es maximizar la rentabilidad esperada, sino encontrar la asignación con menor varianza.

$$\min_{w} \quad w^{\top} \Sigma w \tag{2.11}$$

La cuarta referencia es la optimización de media-varianza (*Mean-Variance*). Esta referencia combina rentabilidad esperada y riesgo dentro de un mismo criterio. En este enfoque no solo se busca reducir el riesgo, a diferencia de la cartera de mínima varianza. Su objetivo es encontrar un equilibrio entre mayor rentabilidad esperada y evitar una

varianza excesiva. Si $\mu$ representa el vector de retornos esperados y $\lambda$ controla la importancia asignada al riesgo, el problema puede expresarse como:

$$\max_{w} \; w^{\top}\mu - \lambda w^{\top}\Sigma w \tag{2.12}$$

Por último, se considera una estrategia pasiva de compra y mantenimiento (*Buy and Hold*). Esta estrategia, como indica su nombre, consiste en mantener la inversión durante todo el periodo sin realizar rebalanceos activos. Este enfoque permite comparar el modelo con una alternativa pasiva vinculada al comportamiento general del mercado.

La siguiente Tabla 2.1 resume los modelos clásicos utilizados como referencia en este trabajo. Se representan el criterio de asignación de activos de cada estrategia y su interpretación financiera.

| Modelo | Criterio de asignación | Interpretación financiera |
|---|---|---|
| Cartera equiponderada *(Equal Weight)* | $w_i = \frac{1}{N}$ | Reparte el capital por igual entre todos los activos. |
| Ponderación inversa a la volatilidad *(Inverse Volatility)* | $w_i = \frac{1/\sigma_i}{\sum_{j=1}^{N} 1/\sigma_j}$ | Da más peso a los activos con menor volatilidad estimada. |
| Cartera de mínima varianza *(Minimum Variance)* | $\min_w \; w^{\top}\Sigma w$ | Busca la cartera con menor varianza dentro del conjunto factible. |
| Optimización media-varianza *(Mean-Variance)* | $\max_w \; w^{\top}\mu - \lambda w^{\top}\Sigma w$ | Equilibra rentabilidad esperada y penalización del riesgo. |
| Compra y mantenimiento *(Buy and Hold)* | Mantener la exposición al índice de referencia | Sirve como referencia pasiva de mercado sin rebalanceo activo. |

***Tabla 2.1.*** *Modelos clásicos de referencia y criterio de asignación. Elaboración propia*

## 2.3 Riesgo, fricciones operativas y métricas de evaluación

Una cartera puede tener buenos resultados en términos de retorno, pero hacerlo a costa de cambios excesivos en los pesos, costes de transacción elevados o caídas importantes. Por ello, este trabajo también considera medidas relacionadas con la rotación de la cartera, los costes operativos, las caídas y la relación entre rentabilidad y riesgo.

Una de las magnitudes más importantes es la rotación de cartera, también conocida como *turnover*. Indica cuánto cambia la composición de la cartera entre dos periodos consecutivos.

$$TO_{t+1} = \frac{1}{2}\sum_{i=1}^{N} | w_{i,t+1} - w_{i,t} | \quad (2.13)$$

$TO_{t+1}$ representa la rotación de la cartera después del rebalanceo. Se calcula con la diferencia del peso de cada activo antes y después de la nueva decisión. Después se suman todos los cambios y se divide entre dos para no contar dos veces el capital que sale de unos activos y entra en otros. Por ello, una rotación alta indica que la estrategia ha hecho una modificación importante en la composición de la cartera.

La rotación de la cartera es importante porque cada cambio en su composición es posible que genere un coste de transacción. En el mercado real, la compraventa de activos no es gratuita, por lo que conviene tener una estrategia donde no haya demasiado rebalanceo porque se puede perder parte de la rentabilidad en costes operativos.

$$C_{t+1} = c \cdot TO_{t+1} \quad (2.14)$$

En esta expresión, $C_{t+1}$ representa el coste asociado al rebalanceo y $c$ indica el coste aplicado por unidad de rotación. A partir de este coste, el retorno neto de la cartera se calcula restándolo al coste de retorno bruto, teniendo en cuenta las fricciones operativas.

$$R_{p,t+1}^{net} = R_{p,t+1} - C_{t+1} \quad (2.15)$$

Otra medida importante es el *drawdown*, analiza las caídas del valor de cartera a lo largo del tiempo. Se centra en cuánto cae la cartera desde el máximo valor alcanzado hasta su momento posterior. Si $V_t$ representa el valor de la cartera en el instante $t$, el *drawdown* puede expresarse como:

$$DD_t = \frac{V_t - \max\limits_{\tau \le t} V_\tau}{\max\limits_{\tau \le t} V_\tau} \quad (2.16)$$

Esta medida toma valores negativos o iguales a cero. Cuando el valor es cercano a cero es porque se encuentra cerca de su máximo acumulado, mientras que un valor negativo significa una caída mayor. A partir de esto, se obtiene el máximo *drawdown*, que es la peor caída dentro del periodo analizado.

Para comparar el rendimiento, también es necesario utilizar métricas que permitan valorar la relación entre la rentabilidad y el riesgo, así como el crecimiento medio obtenido. En este trabajo se utilizan el ratio de Sharpe y la tasa de crecimiento anual compuesta, conocida como CAGR.

$$Sharpe = \frac{R_p - \bar{} R_f}{\sigma_{R_p - R_f}} \sqrt{252} \quad (2.17)$$

El ratio de Sharpe compara la rentabilidad obtenida por encima del activo libre de riesgo entre la variabilidad de esa rentabilidad, es decir, ayuda a ver si la estrategia ha compensado el riesgo asumido. El factor $\sqrt{252}$ se utiliza para expresar el resultado en términos anuales, ya que se trabaja con datos diarios.

$$CAGR = \left(\frac{V_T}{V_0}\right)^{1/Y} - 1 \tag{2.18}$$

El CAGR compara el valor final de la cartera $V_T$ con su valor inicial $V_0$ . Así, indica cuánto habría crecido la cartera de media cada año, teniendo en cuenta el número de años $Y$ del periodo analizado.

Además del CAGR, también se utiliza el ratio de Calmar. Esta métrica compara el crecimiento anual compuesto de la cartera con la peor caída acumulada que ha sufrido durante el periodo evaluado. Su interés está en que no mira solo cuánto ha crecido la cartera, sino también cuánto ha llegado a caer para conseguir ese resultado. Por ello, ayuda a valorar si la rentabilidad obtenida compensa el riesgo asumido en términos de caídas. Se expresa de la siguiente forma:

$$Calmar = \frac{CAGR}{|MaxDrawdown|} \tag{2.19}$$

También se incorpora el CVaR al 95 %, una métrica habitual en gestión de riesgos para analizar cómo se comporta una cartera en escenarios adversos. En este trabajo se utiliza el nivel del 95 % porque permite centrarse en el 5 % de los peores resultados sin depender únicamente de un caso extremo aislado. Además, este nivel ofrece un equilibrio razonable: recoge pérdidas suficientemente desfavorables, pero mantiene un número de observaciones suficiente para que la medida sea interpretable. De esta forma, un valor más negativo indica una mayor exposición a pérdidas extremas, mientras que un valor menos negativo refleja un comportamiento más contenido en situaciones de estrés.

$$CVaR_{95} = \mathbb{E}[r_t \mid r_t \leq q_{5\%}] \tag{2.20}$$

La siguiente Tabla 2.2 resume las principales magnitudes utilizadas en este trabajo para analizar el comportamiento de las estrategias

| Magnitud | Definición operativa | Papel dentro del sistema |
|---|---|---|
| Turnover | $TO_{t+1} = \frac{1}{2}\sum_{i=1}^{N}\lvert w_{i,t+1} - w_{i,t}\rvert$ | Mide cuánto cambia la composición de la cartera entre dos periodos consecutivos. |
| Coste de transacción | $C_{t+1} = c \cdot TO_{t+1}$ | Recoge el coste asociado al rebalanceo en función de la rotación realizada. |
| Retorno neto | $R_{p,t+1}^{net} = R_{p,t+1} - C_{t+1}$ | Representa el rendimiento de la cartera después de descontar las fricciones operativas. |
| Drawdown | $DD_t = \frac{V_t - M_t}{M_t}, \quad M_t = \max_{\tau \le t} V_\tau$ | Mide la caída de la cartera respecto al máximo valor acumulado hasta ese instante. |
| Sharpe anualizado | $Sharpe = \frac{\overline{R_p - R_f}}{\sigma_{R_p - R_f}}\sqrt{252}$ | Compara la rentabilidad obtenida por encima del activo libre de riesgo con su variabilidad. |
| CAGR | $CAGR = \left(\frac{V_T}{V_0}\right)^{1/Y} - 1$ | Indica el crecimiento anual medio de la cartera a lo largo del periodo evaluado. |
| Calmar | $Calmar = \frac{CAGR}{\lvert\, MaxDrawdown \,\rvert}$ | Relaciona el crecimiento anual compuesto con la máxima caída acumulada de la cartera. |
| CVaR 95 % | $CVaR_{95} = \mathbb{E}[r_t \mid r_t \le q_{5\%}]$ | Mide el comportamiento medio de la estrategia en los escenarios más desfavorables de la distribución de retornos. |

***Tabla 2.2.*** *Definición de las principales magnitudes operativas utilizadas en el sistema y de las métricas empleadas para evaluar su comportamiento. Elaboración propia.*

## 2.4 Formulación secuencial del problema de cartera

Este trabajo no plantea la optimización de carteras como una decisión única tomada desde el inicio del periodo, sino como un proceso de decisiones de forma sucesiva. En cada fecha, la cartera parte de la base una composición previa y cualquier modificación de sus

pesos afecta al resultado posterior, tanto en el riesgo asumido como en los costes de rebalanceo. El sistema observa la información disponible, decide cómo ajustar la cartera y evalúa el efecto de esa decisión para el periodo siguiente.

En cada instante *t,* el agente recibe un estado $s_t$ que resume la información disponible para tomar una decisión. El estado está formado por variables de mercado, la composición actual de la cartera, señales auxiliares relacionadas, con el comportamiento propio de los activos y variables de contexto exógeno macro financiero. Se puede representar de la siguiente manera:

$$s_t = [x_t^m, w_t, f_t, x_t^c] \tag{2.21}$$

En la expresión (2.19), $x_t^m$ representa las variables de mercado, $w_t$ los pesos actuales de la cartera, $f_t$ agrupa las señales auxiliares y $x_t^c$ contiene la información de contexto exógeno. Esta estructura está pensada para que la decisión no dependa únicamente del comportamiento reciente de los activos, sino también del entorno financiero observado y de cómo está compuesta la cartera en ese momento.

A partir del estado observado, la política del agente realiza una acción $a_t$. En este trabajo, esta acción no se trata de una cartera construida desde cero, sino como un reajuste sobre la cartera existente. Representada de esta forma:

$$w_t^{tar} = w_t + \Delta w_t(a_t) \tag{3.22}$$

En la expresión (2.20), $\Delta w_t(a_t)$ es el cambio de pesos a partir de la acción del agente, mientras que $w_t^{tar}$ es la cartera objetivo antes de aplicar los controles finales de ejecución. Esta forma de definir la acción del agente permite ver cómo puede cambiar la cartera y, por tanto, generar rotación y costes operativos.

La cartera objetivo generada por la política, antes de aplicarse, pasa por un control de rebalanceo que compara la cartera propuesta con la anterior y limita el cambio si resulta excesivo. De esta forma, mantiene una operativa más estable. De una forma simplificada, este ajuste se puede representar como:

$$w_t^{prop} = w_t + \alpha_t(w_t^{tar} - w_t), \alpha_t \in [0,1] \tag{3.23}$$

En la expresión (2.21), $w_t^{prop}$ $es$ a la cartera propuesta después del control de rebalanceo. El parámetro $\alpha_t$ indica qué parte del cambio sugerido por el agente se aplica finalmente. Si $\alpha_t = 1$, se mantiene todo el ajuste propuesto; si $\alpha_t$ es menor, el cambio se reduce para evitar una rotación excesiva.

Tras el control de rebalanceo, la cartera propuesta debe convertirse en una ejecutable. Por ello, se realiza una capa de seguridad que revisa si los pesos cumplen con las restricciones definidas: suma de pesos igual a uno, ausencia de posiciones negativas y límite máximo por activo. De esta forma, la cartera mantiene una estructura válida desde un punto de vista financiero para este trabajo. Representada de esta forma:

$$w_t^{exec} = Proj_{\mathcal{C}}\left(w_t^{prop}\right) \tag{3.24}$$

En la expresión (2.22), $w_t^{exec}$ es la cartera finalmente ejecutada y $\mathcal{C}$ $es$ el conjunto de carteras válidas. La proyección $Proj_{\mathcal{C}}$ indica que la cartera propuesta se ajusta, si es necesario, al conjunto de restricciones permitido. Esta idea se desarrollará con más detalle en el apartado dedicado a la proyección convexa y en el capítulo de propuesta del modelo.

Una vez obtenida la cartera ejecutada, los retornos quedan expuestos para el periodo siguiente. Con el resultado de ese periodo se calcula una recompensa, que sirve para valorar si la decisión tomada es adecuada. Para la recompensa se tiene en cuenta: el retorno neto, la rotación de cartera y el aumento de las caídas de valor. Se puede expresar como:

$$\rho_{t+1} = F\left(R_{p,t+1}^{net}, TO_{t+1}, L_{t+1}, \Delta DD_{t+1}\right) \tag{3.25}$$

En la expresión (2.23), $\mathrm{R}_{\mathrm{p,t+1}}^{\mathrm{net}}$ es el retorno neto de la cartera, es decir, el rendimiento obtenido descontando los costes operativos. $\mathrm{TO_{t+1}}$ es la rotación generada por el rebalanceo. $\mathrm{L_{t+1}}$ representa el componente asociado a pérdidas, que aparece cuando el retorno neto es negativo. Por último, $\Delta\mathrm{DD_{t+1}}$ mide si la caída acumulada de la cartera ha aumentado respecto al paso anterior. La fórmula completa de la recompensa se desarrollará con profundidad en el capítulo 4. Por ahora, sirve para mostrar que el agente no aprende únicamente de la rentabilidad, sino también de las pérdidas, rotaciones y deterioro de su trayectoria.

Con las definiciones anteriores ya planteadas, la dinámica general del sistema puede resumirse como una cadena de decisión que va desde el estado observado hasta la cartera ejecutada y su recompensa obtenida:

$$s_t \rightarrow a_t \rightarrow w_t^{tar} \rightarrow w_t^{prop} \rightarrow w_t^{exec} \rightarrow (\rho_{t+1}, s_{t+1}) \tag{3.26}$$

El agente observa el estado $s_t$, genera una acción $a_t$, y la acción se transforma en una cartera objetivo $w_t^{tar}$. Después, el control de rebalanceo produce una cartera propuesta $w_t^{prop}$, y la capa de seguridad obtiene la cartera finalmente ejecutada $w_t^{exec}$. A partir de esa ejecución se calcula la recompensa $\rho_{t+1}$ y el sistema avanza hasta el siguiente estado $s_{t+1}$. Esta formulación resume la base para el siguiente apartado, donde se introduce el algoritmo utilizado para el aprendizaje de la política de decisión.

## 2.5 Aprendizaje por refuerzo profundo y algoritmo PPO

El aprendizaje por refuerzo profundo se basa en la idea de que un agente aprenda a tomar decisiones mediante una interacción continua con un entorno. En cada paso, el agente observa la situación, realiza una acción y recibe una recompensa según el resultado obtenido. Esa información se utiliza para ajustar su forma de actuar y mejorar las decisiones que le dan mejores resultados. En este trabajo, el entorno representa la evolución del mercado y de la cartera.

En este trabajo se utiliza aprendizaje por refuerzo profundo porque el estado del agente consta de distintos tipos de información y no se puede representar por una regla simple.

A partir de esta información debe decidir cómo ajustar los pesos de cartera. Por ello, la política del agente se aproxima mediante una red neuronal, que le permite aprender relaciones complejas, a diferencia de una regla fija tradicional.

PPO se utiliza como el método encargado de ajustar las acciones del agente. Su funcionamiento se basa en que, a partir de los estados observados y recompensas obtenidas, el algoritmo modifica gradualmente los parámetros de la política para que sus decisiones futuras sean más favorables. Por ello, va aprendiendo una regla de decisión que indique como reajustes los pesos a partir de la información que disponga.

No es un algoritmo que se diferencie por generar acciones a partir de un estado, esta función es común en otros métodos por aprendizaje profundo. Su papel fundamental es la forma que tiene de actualizar durante el entrenamiento. PPO limita los cambios entre la política anterior y la nueva. Es una forma de aprendizaje que forma avances progresivos y no mediante actualizaciones bruscas, es una característica muy útil con relación carteras porque pequeñas actualizaciones de política pueden generar cambios muy importantes en los pesos asignados de los activos. La formulación, propuesta por Schulman et al. (2017), es expresada de la siguiente manera:

$$L^{CLIP}(\theta) = \mathbb{E}_t\left[\min\left(r_t(\theta)\hat{A}_t, clip(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right] \tag{2.27}$$

$$r_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{old}}(a_t \mid s_t)} \tag{2.28}$$

En estas expresiones, $r_t(\theta)$ compara la probabilidad de generar la acción $a_t$ con la política nueva frente a la política anterior. El término $\hat{A}_t$ indica si la acción tomada ha sido mejor o peor de lo esperado, y $\epsilon$ fija el margen máximo de cambio permitido. La función $clip$ recorta ese cambio dentro del intervalo $[1-\epsilon, 1+\epsilon]$. De esta forma, PPO permite que la política mejore durante el entrenamiento, pero evitando cambios demasiado bruscos que pueden hacer que el aprendizaje sea inestable.

## 2.6 Restricciones, conjunto factible y proyección convexa

La propuesta de cartera generada por la política del agente no siempre tiene por qué cumplir con las restricciones necesarias para ser ejecutadas. Por ello, es necesario la definición de un conjunto de carteras válidas. Este conjunto sirve como referencia para la capa de seguridad ya que recoge las restricciones de factibilidad: inversión total del capital, ausencia de pesos negativos y límite máximo por activo. Se consideran estas tres restricciones porque definen las condiciones mínimas para que una cartera sea ejecutable dentro del planteamiento realizado. Otros elementos, como rotación o costes de transacción se consideran como mecanismos de control operativo y no como unas restricciones duras. Esta idea será desarrollada más adelante en el capítulo cuatro de propuesta del modelo. De manera compacta, el conjunto de carteras válidas se puede expresar de esta manera:

$$\mathcal{C} = \{w: \mathbf{1}^\top w = 1,\ w_i \geq 0,\ w_i \leq w_{\max},\ i = 1, \ldots, N\} \tag{2.29}$$

En la expresión (2.27), $\mathcal{C}$ es el conjunto de carteras que cumplen las restricciones anteriores. La condición $\mathbf{1}^\top w = 1$ garantiza que todo el capital disponible queda asignado, $w_i \geq 0$ impide posiciones negativas y $w_i \leq w_{\max}$ limita la concentración máxima permitida en cada activo.

Una vez definido el conjunto de carteras válidas, la capa de seguridad es un ajuste final sobre la propuesta del agente. Si la cartera propuesta no cumple con alguna de las restricciones, el sistema busca una nueva cartera que sí sea válida y que sea lo más cercana posible a esa propuesta inicial. De esta forma, la modificación realizada es la mínima necesaria para que la asignación final pueda ejecutar

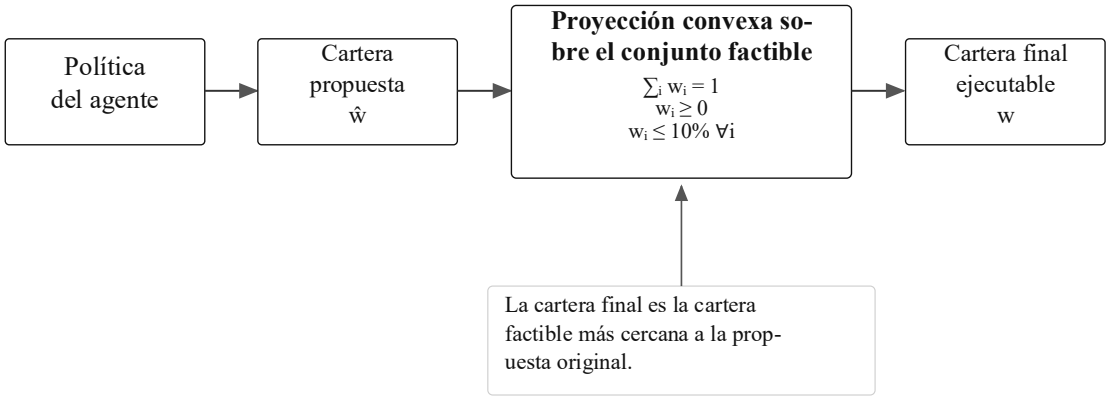



***Figura 2.1.*** *Esquema de la capa de seguridad convexa y su integración en el flujo de decisión del agente. Elaboración propia.*

# Capítulo 3. Estado del arte

La optimización de carteras es uno de los temas principales dentro de las finanzas cuantitativas, dado que implica decidir en qué activos distribuir el capital con el objetivo de obtener la mejor relación entre rentabilidad y riesgo. Durante años recientes, se observa una transformación progresiva: antes dominaban estructuras fijas que dependían de retornos esperados, varianza y covarianza; ahora predominan métodos cambiantes, preparados para entornos variables, costes de transacción, restricciones operativas y periodos de inestabilidad que dificultan el uso de las estrategias de enfoques estáticos. Por ello, en los últimos años ha habido un creciente interés por tratar las inversiones como procesos dinámicos, donde las decisiones se reajustan a partir de la evolución del entorno.

Este capítulo se articula en distintos apartados. En primer lugar, se presentan los fundamentos clásicos de la optimización de carteras y cómo ha ido evolucionando hacia formulaciones más dinámicas. Después, se analiza el uso del aprendizaje por refuerzo profundo enfocado a la gestión de carteras, profundizando en el algoritmo PPO y a su aplicación en problemas de decisión continua. A continuación, se estudia la representación del estado financiero, incluyendo redes neuronales, contexto exógeno, regímenes de mercado y mecanismos de *gating.* Por último, se revisan los conceptos de riesgo, restricciones operativas, los costes de transacción y la evaluación experimental. El capítulo concluye con la identificación del hueco de investigación en el que se sitúa el trabajo.

## 3.1 Optimización clásica de carteras y transición hacia decisiones dinámicas

Desde el análisis pionero de Markowitz (1952), la optimización de carteras se ha planteado como un problema que busca el equilibrio entre rentabilidad esperada y riesgo. El enfoque media-varianza propone que no basta con escoger activos de una forma aislada, sino que importa cómo se combinan dentro de una cartera y cómo se relacionan sus rendimientos entre sí. A partir de este planteamiento, surgen conceptos importantes como la diversificación y la frontera eficiente, que ayudan a analizar qué combinaciones de activos ofrecen una mejor relación entre rentabilidad y riesgo bajo ciertas condiciones. Este análisis sigue manteniendo vigencia y, aunque se trate de una formulación clásica, constituye un pilar fundamental para desarrollos posteriores dentro de las finanzas cuantitativas.

A pesar de su importancia, la optimización media-varianza presenta ciertas limitaciones cuando se trata de aplicarla a datos reales. Michaud (1989) menciona que estos métodos pueden llevar a pequeños errores de estimación, dado que variaciones leves en los cálculos de medias esperadas o covarianzas suelen generar carteras exageradas o poco estables. Siguiendo esta línea, DeMiguel, Garlappi y Uppal (2009) señalaron que numerosas estrategias optimizadas no consiguen superar de forma estable a una cartera

1/N cuando se prueban fuera de muestra, ya que los errores de estimación pueden reducir la ventaja teórica que proporciona el modelo.

Estas limitaciones explican por qué muchas estrategias simples siguen utilizándose como referencias fuertes en la literatura y en la práctica profesional. Entre ellas destacan la cartera equiponderada, la ponderación inversa a la volatilidad, la cartera de mínima varianza y distintas variantes derivadas del enfoque media-varianza. Así pues, nuevos métodos basados en algoritmos de aprendizaje por refuerzo deben medirse contra estas alternativas clásicas, dado que definen el nivel necesario para validar diseños más elaborados.

Uno de los principales límites de los enfoques clásicos es su carácter estático. Aunque existen modelos que consideran distintos periodos, en la práctica muchas formulaciones calculan una cartera en momentos concretos y se reajustan periódicamente. En un problema real de gestión de carteras, sin embargo, las decisiones actuales condicionan el estado futuro, es decir, influyen en la composición heredada, en los costes derivados de ajustar las posiciones y en el riesgo acumulado de la cartera.

Por este motivo, tiene sentido pasar de una visión estática de cartera a una formulación de decisión secuencial. En este marco, el agente observa el estado del entorno, propone una decisión de rebalanceo y recibe una recompensa asociada al resultado económico y al riesgo asumido. Frente a la asignación aislada, esta formulación permite incorporar de forma conjunta la posición previa de la cartera, los costes de rebalanceo, las restricciones y la evolución temporal del mercado.

El aprendizaje por refuerzo resulta interesante en este contexto porque permite aprender políticas de decisión a partir de la interacción con el entorno. En lugar de entender una cartera como una estrategia estática, pasa a verse como una estrategia dinámica que se reajusta periódicamente según las variables de mercado y la evolución de la posición de la cartera. Este punto de partida sirve para continuar, en el siguiente apartado, con los trabajos que aplican aprendizaje por refuerzo profundo a la gestión dinámica de carteras.

## 3.2 Aprendizaje profundo y representación del estado en gestión de carteras

Plantear este problema como una secuencia de decisiones ayuda a entender por qué encaja el aprendizaje por refuerzo profundo en la metodología del modelo para el estudio de la gestión dinámica de carteras. El sistema no se limita a aplicar una regla fija, sino que aprende en base a una política de decisión a partir de la interacción con un entorno. Revisiones recientes, como la de Bai et al. (2025), señalan que el aprendizaje por refuerzo gana presencia en distintos problemas financieros, pero también destaca que su rendimiento depende de cómo se define el entorno, el tratamiento del riesgo y el diseño de la evaluación del modelo.

Una de las referencias en esta línea es el trabajo de Jiang, Xu y Liang (2017), que plantea un marco directamente enfocado en el aprendizaje por refuerzo profundo aplicado a la gestión de carteras. Su idea principal es que la política de decisión aprenda pesos de asignación a partir de datos de mercado. En su propuesta, el estudio se implementa con distintas arquitecturas neuronales como CNN (*Convolutional Neural Networks*), RNN (*Recurrent Neural Networks*) y LSTM (L*ong Short-Term Memory*) y el estudio se centra dentro del mercado de criptomonedas. Aun así, este estudio resulta relevante porque muestra una forma de tratar la asignación de una cartera como una política aprendida por el agente.

Posteriormente, Ye et al. (2020) reforzaron la importancia del diseño del estado mediante su propuesta SARL (*State-Augmented Reinforcement Learning*), donde el agente recibe una representación ampliada con señales auxiliares sobre el movimiento de los activos. Este trabajo resulta especialmente relevante porque muestra que el rendimiento del sistema no depende únicamente del algoritmo de RL (*Reinforcement Learning*) utilizado, sino también de la calidad informativa del estado y de su capacidad para captar incertidumbre y heterogeneidad del entorno financiero.

Dentro de los algoritmos de aprendizaje por refuerzo profundo, PPO es uno de los métodos más utilizados. Fue introducido por Schulman et al. (2017), siendo su concepto principal que la política de decisión sea actualizada de forma controlada. En un contexto de ajustes de carteras puede resultar útil debido a que el agente no elige una categoría cerrada, sino distintas proporciones de capital entre diversos activos. Además, otros trabajos recientes como Espiga-Fernández et al. (2024) incluyen PPO en su investigación entre los distintos algoritmos para el estudio de problemas de optimización de carteras.

En el ámbito financiero, PPO resulta especialmente beneficioso porque la asignación de cartera puede formularse como un problema de control continuo. Esta estabilidad es especialmente valiosa en escenarios donde la señal de recompensa es ruidosa y el espacio de decisión es amplio. En esta línea, Choudhary et al. (2025) implementan agentes PPO para diseñar una estrategia para la optimización de carteras ajustadas al riesgo con distintas funciones de recompensa. Por ello, se muestra que este algoritmo sigue siendo utilizado en trabajos recientes para la asignación dinámica de carteras y control de riesgo.

Existen, no obstante, alternativas potencialmente competitivas, como DDPG (*Deep Deterministic Policy Gradient*; Lillicrap et al., 2015), SAC (*Soft Actor-Critic*; Haarnoja et al., 2018) y TD3 (*Twin Delayed Deep Deterministic Policy Gradient*; Fujimoto et al., 2018), especialmente en problemas de alta dimensión. Sin embargo, estos algoritmos suelen requerir un ajuste más delicado y pueden mostrar mayor sensibilidad a los parámetros de entrenamiento. Por ello, PPO sigue considerándose una base especialmente adecuada cuando el objetivo no es solo alcanzar buen rendimiento, sino construir una plataforma experimental estable sobre la que introducir mecanismos adicionales de contexto, modulación y seguridad.

Además del algoritmo de aprendizaje, la arquitectura encargada de representar el estado observado también resulta fundamental para el rendimiento del sistema. El rendimiento de estos sistemas no depende solo del algoritmo de aprendizaje utilizado, sino también de la forma en que se representa la información financiera antes de llegar a la política. En este sentido, las arquitecturas más sencillas, como los perceptrones multicapa, suelen emplearse cuando el estado ya contiene variables previamente calculadas, como retornos o volatilidad. Las redes convolucionales, por su parte, se han utilizado para trabajar con matrices de precios, volúmenes o indicadores, ya que pueden extraer patrones locales entre activos o entre ventanas temporales. Cuando se quiere representar mejor la evolución temporal de los datos, aparecen las redes recurrentes y las LSTM, que permiten procesar secuencias bursátiles y conservar información de periodos anteriores (Jiang et al., 2017).

En tiempos recientes, los modelos basados en *Transformers* han ganado interés por la capacidad para trabajar con mecanismos de atención. Son mecanismos que permiten identificar qué información resulta relevante en cada momento. Gracias al uso de mecanismos de atención, algunos estudios logran representar patrones persistentes a través del tiempo. Por ejemplo, Wang y Liu (2025) proponen un marco de aprendizaje por refuerzo profundo sensible al riesgo basado en *Transformers*, mientras que Xue y Ye (2026) combinan aprendizaje por refuerzo con mecanismos de atención para optimización dinámica de carteras. A pesar de ello, trabajar con estos sistemas puede complicarse si hay escasez de datos suficientes. Su funcionamiento requiere gran poder de procesamiento, algo que limita su implementación frecuente. Además, ajustar sus parámetros resulta difícil cuando las señales son poco claras durante el aprendizaje. Otro aspecto relevante: la dinámica constante del entorno altera la estabilidad del proceso formativo. Por esta razón, aunque ofrecen ventajas, también presentan retos importantes en contextos reales. Por ello, varios trabajos siguen considerando razonable el uso de arquitecturas más sencillas y estables cuando el estado ya incorpora variables cuidadosamente construidas que resumen el pasado reciente, como retornos a distintos horizontes, volatilidades, *momentum* o factores agregados de mercado. Desde este punto de vista, la elección de la arquitectura no debe entenderse como una carrera por maximizar complejidad, sino como una decisión metodológica que debe equilibrar capacidad de representación, estabilidad de entrenamiento y viabilidad experimental.

La Tabla 3.1 resume los principales enfoques de representación neuronal utilizados en la literatura revisada, indicando qué aporta cada uno y cuáles son sus principales ventajas y limitaciones.

| Método | Papel en carteras | Ventaja principal | Limitación principal |
|---|---|---|---|
| **MLP** (**Raffin et al., 2021; Choudhary et al., 2025**) | Procesa variables financieras ya construidas, como retornos, volatilidad o indicadores técnicos. | Sencillo, estable y adecuado cuando el estado ya resume bien la información relevante. | No capta por sí solo dependencias temporales complejas si no están recogidas en las variables de entrada. |
| **CNN** (**Jiang et al., 2017**) | Extrae patrones a partir de matrices de precios, volúmenes o indicadores financieros. | Puede detectar estructuras locales entre activos o entre ventanas temporales próximas. | Depende mucho de cómo se organice la entrada y puede resultar menos interpretable financieramente. |
| **RNN** (**Jiang et al., 2017**) | Procesa secuencias financieras conservando información de pasos anteriores. | Permite representar cierta dependencia temporal en precios, retornos o estados sucesivos. | Puede tener dificultades con secuencias largas y con señales financieras ruidosas. |
| **LSTM** (**Jiang et al., 2017**) | Amplía las redes recurrentes para conservar información temporal durante más pasos. | Mejora la memoria temporal frente a una RNN simple y se adapta bien a series financieras. | Es más costosa de entrenar y sensible a la elección de hiperparámetros. |
| **Transformers / atención** (**Wang y Liu, 2025; Xue y Ye, 2026**) | Asignan más peso a las partes más relevantes de una secuencia o del estado observado. | Captan relaciones complejas y dependencias largas sin procesar la secuencia de forma estrictamente recurrente. | Tienen mayor complejidad, requieren más datos y pueden sobreajustarse en entornos financieros ruidosos. |
| **Gating / modulación** (**Hu et al., 2018; Woo et al., 2018; Perez et al., 2018; Gu et al., 2025**) | Regula la influencia de una fuente de información antes de integrarla con otra. | Permite incorporar contexto de forma selectiva, evitando tratar todas las señales como igualmente útiles. | Añade complejidad y exige justificar cómo se interpreta la modulación aprendida. |

***Tabla 3.1*** *Principales arquitecturas de representación utilizadas en aprendizaje profundo aplicado a carteras. Elaboración propia.*

Además de la arquitectura utilizada, es importante qué información debe incluirse dentro del estado observado del agente. Una de las líneas más visibles consiste en ampliar el estado del agente con información distinta de los precios históricos. Las revisiones más actuales coinciden en que el rendimiento de estos sistemas depende no solo del algoritmo utilizado, sino también de cómo se define el estado y de si este es capaz de reflejar la complejidad de un entorno financiero no estacionario. En ese marco, el uso de contexto exógeno aparece como una forma de incorporar señales que no quedan recogidas de manera inmediata en precios y volúmenes. Por ejemplo: inflación, tipos de interés, condición monetaria o indicadores de tensión financiera. Este tipo de información externa puede ayudar a representar de una forma más precisa el entorno financiero. En esta línea, Ye et al. (2020) ya muestran la importancia de enriquecer el estado del agente con información adicional, mientras que trabajos más recientes, como Yang (2023) o Wang

y Liu (2025), refuerzan la idea de que la calidad de la representación del estado es un elemento clave en la gestión de carteras con aprendizaje por refuerzo.

Un antecedente importante en esta línea es el trabajo de Ye et al. (2020), ya citado anteriormente, que propone el marco SARL para enriquecer la representación del estado con información adicional derivada de predicciones de movimiento de activos, construidas tanto a partir de datos financieros como de fuentes alternativas como noticias. En paralelo, trabajos más recientes sobre asignación táctica han incorporado directamente variables macroeconómicas para caracterizar el entorno. Por ejemplo, Oliveira et al. (2025) utilizan FRED-MD (*Federal Reserve Economic Data – Monthly Database*), una base de datos macroeconómica mensual en base a la Reserva Federal de St. Louis, para identificar condiciones generales de mercado y trasladarlas al proceso de asignación de activos. Esta orientación refuerza la idea de que las decisiones de cartera pueden beneficiarse de una representación del estado más amplia que la proporcionada por los retornos pasados.

No obstante, la literatura no presenta el contexto exógeno como una solución automática. Las revisiones recientes señalan que una ampliación poco selectiva del estado puede introducir ruido, redundancia o sobreajuste, especialmente cuando se incorporan muchas señales externas sin un criterio claro de relevancia. Por ello, una cuestión todavía abierta no es solo si la información macro financiera puede aportar valor, sino también en qué condiciones lo hace y cómo debe integrarse para mejorar la robustez fuera de muestra en lugar de deteriorarla.

La detección de regímenes de mercado ocupa un lugar consolidado en la literatura de asignación de activos porque parte de una idea básica: los mercados no evolucionan bajo una única dinámica, sino a través de fases con combinaciones distintas de volatilidad, correlación, dispersión y condiciones macroeconómicas. Desde esta perspectiva, el rendimiento de una estrategia no debe evaluarse solo de forma agregada, sino también en función del tipo de entorno en el que opera. En este sentido, Oliveira et al. (2025) muestran cómo la información macroeconómica para identificar regímenes y trasladarlos al proceso de asignación de activos.

Dentro de este campo, una de las aproximaciones relevantes es el uso de modelos probabilísticos capaces de representar el entorno mediante varios estados con distintos grados de pertenencia. En esta línea, Buckley, Saunders y Seco (2008) plantean la optimización de carteras bajo una mezcla gaussiana, asociando sus componentes a estados como fases de tensión y fases de mayor estabilidad, lo que muestra que la idea de modelar el mercado como combinación de regímenes diferenciados tiene un recorrido amplio en finanzas. Este tipo de formulaciones resulta especialmente atractivo cuando no se busca una clasificación rígida, sino una representación gradual del cambio de entorno.

Aun así, la literatura deja abiertas varias cuestiones. No existe un criterio único sobre cuántos regímenes deben definirse ni sobre qué variables describen mejor cada fase del mercado, y algunos trabajos recientes subrayan que construirlos solo a partir de retornos

puede introducir demasiado ruido. Por eso, propuestas actuales de asignación de activos basada en regímenes recurren a datos macroeconómicos más estables para extraer esa estructura latente y utilizarla después en la construcción de la cartera. En consecuencia, la detección de regímenes puede ayudar a predecir y evaluar el entorno del mercado, pero sigue siendo un área abierta la cuestión de cómo definirlos de forma más robusta para problemas de cartera.

La simple concatenación de información de mercado y contexto exógeno no garantiza una integración eficiente de ambas fuentes. Si el contexto no resulta informativo en determinados periodos, su incorporación puede introducir ruido y perjudicar el rendimiento del agente. Para mitigar este problema, distintos campos del aprendizaje profundo han desarrollado mecanismos de *gating* que permiten modular selectivamente la influencia de determinadas señales o ramas de representación.

En arquitecturas recurrentes, como GRU (*Gated Recurrent Unit*) y LSTM, el *gating* se utiliza para decidir qué información debe conservarse o descartarse a lo largo del tiempo. En visión por computador, módulos como *Squeeze-and-Excitation Networks* (Hu et al., 2018) o CBAM *(Convolutional Block Attention Module*; Woo et al., 2018) ajustan características según su relevancia contextual. En una línea relacionada, FiLM (*Feature-wise Linear Modulation;* Perez et al., 2018) plantea esquemas de modulación condicionada donde una señal externa altera de forma aprendida la representación interna del modelo. Aunque estas propuestas proceden de otros dominios, ofrecen un marco conceptual útil para pensar cómo integrar contexto heterogéneo de manera selectiva.

En finanzas, esta línea todavía es menos extensa, pero empiezan a aparecer trabajos que incorporan mecanismos de atención o *gating* para fusionar información heterogénea en entornos no estacionarios. Por ejemplo, Gu et al. (2025) proponen un marco basado en *Memory Instance Gated Transformer* para gestión de carteras, incorporando un módulo de atención con compuertas orientado a mejorar la estabilidad del aprendizaje y reducir el efecto de valores atípicos. Aunque su planteamiento se basa en una arquitectura distinta a la que se plantea en este trabajo, resulta interesante porque refuerza la idea de modulación selectiva de información. La idea central es que la utilidad del contexto no es constante en el tiempo y, por tanto, el sistema debería aprender no solo a procesarlo, sino también a decidir cuándo debe influir más o menos en la política de asignación.

## 3.3 Estrategias de evaluación

En gestión de carteras, evaluar la estrategia solamente por la rentabilidad obtenida puede ser insuficiente. Un sistema puede conseguir buenos datos en términos de retorno, pero hacerlo asumiendo caídas elevadas, cambios grandes en la composición o costes de transacción difíciles de llevar en la práctica. Por ello, se insiste en incorporar criterios relacionados con el riesgo, la rotación de cartera, la máxima caída acumulada y la estabilidad operativa de la cartera, a través de la recompensa ajustada al riesgo (Choudhary et al., 2025). Este planteamiento resulta relevante porque condiciona el comportamiento que aprende el agente.

Por ello, una parte de la literatura diseña funciones de recompensa que incorporan explícitamente sensibilidad al riesgo. Los costes de transacción y rotación de cartera tienen un papel importante. Por este motivo, enfoques recientes dentro de la optimización dinámica de cartera incorporan control de rotación y costes dentro del proceso de aprendizaje del modelo. En el trabajo de Xue y Ye (2026) destacan esta importancia de mantener niveles realistas para rotación y máxima caída acumulada para la evaluación de las políticas de aprendizaje por refuerzo.

Además de los riesgos y costes, es importante que la estrategia de cartera deba cumplir unas restricciones operativas básicas. En la práctica, no basta con que la asignación sea rentable, la cartera debe resultar válida. Se deben respetar condiciones como la inversión de todo el capital disponible, limitar un peso máximo asignado a cada activo y evitar pesos negativos cuando se trabaja con una estrategia con posiciones largas. Son las bases para mantener una estructura coherente en la estrategia desde un punto de vista financiero.

En el aprendizaje por refuerzo, estas restricciones pueden ser implementadas de distintas formas. Una de ellas consiste en añadir penalizaciones dentro de la función de recompensa. De esta manera, el agente aprende a evitar comportamientos no deseados. Sin embargo, esta solución no siempre garantiza que se cumplan todas las condiciones señaladas. Otra alternativa consiste en corregir la acción propuesta antes de ejecutarla. Esta idea se relaciona con el aprendizaje por refuerzo seguro. El objetivo no es solo aprender una política rentable, sino asegurar que esas decisiones respeten ciertos límites durante la ejecución (Wachi et al., 2024). Esta distinción resulta importante para este trabajo, ya que la propuesta combina penalizaciones en la recompensa con una capa posterior de control.

Desde el punto de vista financiero, la proyección convexa resulta útil porque permite corregir la propuesta inicial del agente y convertirla en una cartera que pueda ejecutarse realmente, respetando las restricciones definidas. Además, el uso de herramientas como CVXPY (Diamond & Boyd, 2016) y *solvers* cuadráticos como OSQP (Stellato et al., 2020) facilita la incorporación de restricciones adicionales sin modificar la lógica general del sistema. Por ello, las capas de seguridad convexa resultan especialmente apropiadas en trabajos que buscan combinar flexibilidad del agente con garantías mínimas de coherencia operativa.

La evaluación experimental es un pilar fundamental dentro de los trabajos de aprendizaje por refuerzo aplicado a finanzas. No es suficiente con sugerir un agente; es imprescindible desarrollar entornos de evaluación que faciliten la comparación de resultados de manera transparente. Plataformas como FinRL-Meta (Liu et al., 2022) proponen una librería con entornos de mercado y *benchmarks* para aprendizaje por refuerzo financiero, señalando el sesgo de supervivencia. TradeMaster (Sun et al., 2023) también facilita la experimentación al trading y compara esos resultados bajo un marco común.

La evaluación de carteras puede presentar dificultades, ya que los resultados pueden depender en gran medida de cómo se organice la prueba. En primer lugar, los datos financieros tienen una estructura temporal estricta, por lo que no se pueden mezclar libremente observaciones pasadas y futuras sin riesgo de obtener una evaluación demasiado optimista. Además, los mercados son cambiantes con el tiempo: una estrategia que funciona bien en un periodo puede tener un peor resultado cuando cambian las condiciones. Por ello, la evaluación no debe limitarse a medir la rentabilidad final, sino que debe comprobar si la estrategia mantiene un comportamiento estable, realista y comparable en distintos escenarios de mercado.

Entre los elementos más sensibles se encuentran la elección del universo de activos, el tratamiento de los datos ausentes, la inclusión o no de costes de transacción, la definición de métricas y la separación temporal entre entrenamiento, validación y prueba. López de Prado (2018) ha insistido especialmente en la necesidad de respetar la estructura temporal de los datos para evitar contaminación informativa entre entrenamiento y test. Junto a ello, existe otra limitación relevante: el sesgo de supervivencia, que aparece cuando se trabaja con una lista fija de activos que han permanecido disponibles hasta el final del periodo. Esto puede hacer que el rendimiento obtenido parezca mejor de lo que habría sido en una situación real.

Por último, la comparación con estrategias consolidadas es necesaria para valorar si un modelo más complejo puede aportar una mejora. Trabajos citados como Xue y Ye (2026) utilizan un esquema de validación *walk-forward* y comparan su propuesta con estrategias de referencia, incluyendo aspectos como la rotación de la cartera y la máxima caída acumulada. Esta línea refuerza la necesidad de evaluar los modelos no solo por su rentabilidad sino por su riesgo, estabilidad operativa y capacidad de mantener resultados consistentes en los distintos periodos de mercado.

## 3.4 Síntesis del estado del arte y hueco de investigación

La revisión realizada permite extraer varias conclusiones. En primer lugar, los métodos clásicos siguen siendo una base fundamental y una referencia necesaria para comparar nuevas propuestas. Sin embargo, cuando se aplican en entornos reales, pueden presentar limitaciones debido a los errores de estimación, los costes de operación, las restricciones de la cartera y los cambios en las condiciones del mercado. En segundo lugar, el aprendizaje por refuerzo profundo ofrece una forma adecuada de plantear la asignación

de carteras como un proceso de decisiones sucesivas. En lugar de calcular una única cartera fija, permite que el agente ajuste sus decisiones según la información disponible en cada momento y según la cartera que ya tenía construida. En tercer lugar, los trabajos más recientes muestran una tendencia hacia modelos que representan mejor el estado del mercado, incorporan el riesgo de forma más explícita, utilizan señales de contexto y aplican evaluaciones temporales más rigurosas.

No obstante, siguen existiendo varias carencias relevantes. Una parte importante de la literatura continúa trabajando con estados dominados por precios históricos o con integración poco estructurada de señales externas. Del mismo modo, muchos trabajos introducen el riesgo únicamente a través de la recompensa, sin combinarlo con mecanismos explícitos de control operativo o de factibilidad. Tampoco es habitual encontrar propuestas que analicen conjuntamente, dentro de un mismo marco experimental, el efecto del contexto macro financiero, la modulación adaptativa de dicho contexto, la detección explícita de cambios de régimen y la imposición de restricciones duras mediante proyección convexa.

A partir de este hueco, el presente trabajo se sitúa en el diseño y evaluación de un sistema de optimización dinámica de carteras que combina aprendizaje por refuerzo profundo con cuatro elementos complementarios: incorporación de contexto macro financiero exógeno, modulación adaptativa de ese contexto mediante mecanismos de *gating*, identificación de cambios en el entorno mediante señales de régimen, junto con mecanismos de control y seguridad que ayudan a mantener la cartera dentro de unas condiciones operativas válidas. La aportación del trabajo no se limita, por tanto, a entrenar un agente de asignación, sino a estudiar si esa combinación puede ofrecer un equilibrio más robusto entre rentabilidad, riesgo y estabilidad fuera de muestra que los enfoques basados exclusivamente en información de mercado o únicamente en penalizaciones blandas.

# Capítulo 4. Propuesta del modelo, arquitectura y solución

## 4.1 Visión general y esquema del sistema propuesto

El modelo propuesto se organiza como un sistema secuencial que transforma la información observada en una decisión de cartera y, posteriormente, en una cartera ejecutable. Para facilitar la explicación del esquema, la arquitectura se divide en dos bloques: un bloque de decisión que es encargado de procesar el estado observado y generar una cartera objetivo (la asignación que propone inicialmente el agente), y un bloque de ejecución, encargado de aplicar los controles y restricciones necesarios para convertirla finalmente en la cartera final ejecutada (la asignación que se aplica finalmente en el entorno). Más adelante, se calcula la recompensa y se avanza al siguiente estado.

Antes de describir cada componente por separado, resulta útil presentar la arquitectura completa del sistema propuesto. La Figura 4.1 resume cómo funciona el flujo del modelo.

**Figura 4.1. Esquema general del sistema propuesto**

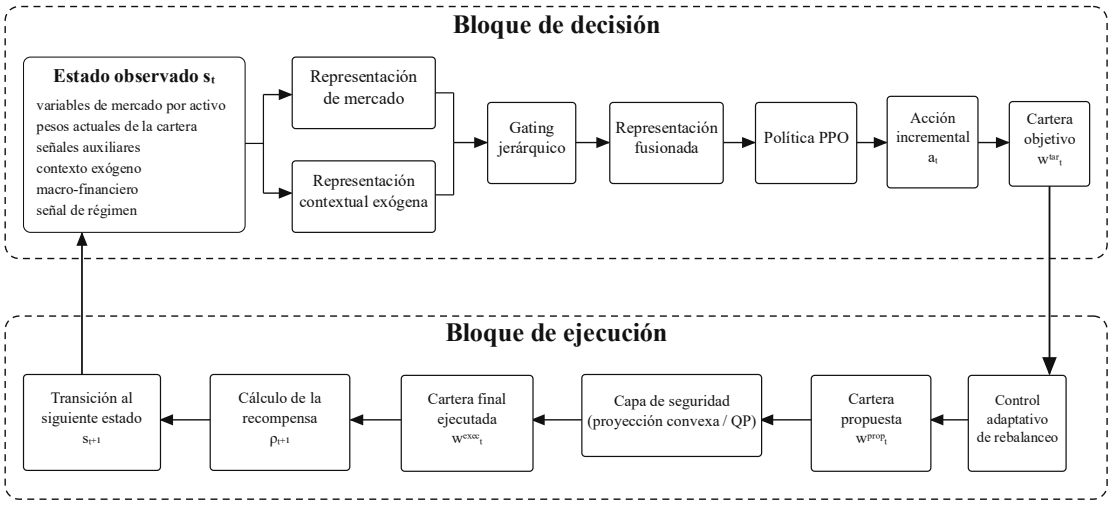



***Figura 4.1.*** *Arquitectura general del sistema propuesto, desde la construcción del estado observado hasta la ejecución final de la cartera bajo control operativo y restricciones de factibilidad. Elaboración propia.*

Como se observa en el esquema, el sistema parte del estado observado $s_t$, que agrupa la información disponible antes de tomar una decisión. De esta información, se diferencian dos ramas: una centrada en la información del mercado y otra orientada al contexto exógeno. Posteriormente, el mecanismo de *gating* es el filtro que ajusta la influencia del contexto exógeno antes de combinarla con la representación de mercado. A partir de esta combinación se obtiene la representación final del estado, que es la que la política PPO utiliza para generar la acción incremental $a_t$. Esta acción incremental es la encargada que

de no construya la cartera desde cero sino, que propone cómo modificar los pesos existentes hasta llegar a esta cartera objetivo $w_t^{tar}$.

La cartera objetivo $w_t^{tar}$ no se ejecuta directamente, sino que pasa al bloque de ejecución. En esta fase, el sistema primero controla la intensidad del rebalanceo para evitar cambios excesivos en los pesos y se obtiene la cartera de propuesta $w_t^{prop}$. Después, esta cartera se ajusta mediante la capa de seguridad que garantiza una asignación final financiera coherente con el modelo. El resultado es la cartera finalmente ejecutada $w_t^{exec}$, a partir de la cual se calcula la recompensa $\rho_{t+1}$ y se avanza al siguiente estado $s_{t+1}$.

La implementación completa del sistema descrito en este capítulo se encuentra disponible en el repositorio público asociado al proyecto[1]. En él se incluyen los módulos encargados del preprocesamiento de datos, la construcción del estado, la arquitectura PPO con mecanismo de *gating*, el entorno de cartera, la función de recompensa, la capa de seguridad y el procedimiento de evaluación *walk-forward*. De esta forma, el capítulo se centra en explicar el diseño y funcionamiento del modelo, mientras que el repositorio permite consultar la implementación completa utilizada en los experimentos.

## 4.2 Datos, universo de activos y construcción del estado

El sistema se construye sobre un universo de 100 activos pertenecientes al S&P 500, con datos diarios comprendidos entre enero de 2010 y diciembre de 2024. Esta selección permite trabajar con una cartera amplia para recoger distintas dinámicas del mercado estadounidense, pero manteniendo una dimensión manejable para el entrenamiento y la validación del modelo. La propuesta puede generalizarse a otros universos de inversión y periodos temporales, siempre que se disponga de datos históricos suficientes, con una periodicidad comparable y preparados bajo los mismos criterios para precios, volúmenes y variables externas. No obstante, para reproducir el esquema experimental de este trabajo sí sería necesario disponer, como mínimo, de seis años consecutivos de datos, ya que cada ventana *walk-forward* combina cuatro años de entrenamiento, un año de validación y un año de prueba. Además, se utiliza el ETF SPY[2] como referencia de mercado. Este ETF replica el comportamiento del índice S&P 500, por lo que sirve como aproximación sencilla al rendimiento general del mercado. En este trabajo se emplea, por un lado, para construir algunas señales agregadas del entorno, como la volatilidad media del universo, la relación entre los movimientos de los activos y la evolución del índice de referencia. Por otro lado, también se utiliza para definir una referencia pasiva de comparación basada en *Buy and Hold.*

Los activos seleccionados se organizan por sectores económicos, con el objetivo de que el universo de inversión no dependa únicamente de un tipo concreto de empresa. En concreto, la lista incluye compañías de tecnología, salud, banca, energía, industria, consumo, servicios públicos, inmobiliario y materiales. Esta clasificación no se utiliza

[1] Repositorio del proyecto: https://github.com/lmg136-ua/gated-ppo-portfolio-optimization
[2] ETF SPY consultado en Yahoo Finance: https://finance.yahoo.com/quote/SPY/.

como una regla directa de inversión, sino como criterio de construcción del universo, buscando que el agente trabaje con activos expuestos a dinámicas de mercado diferentes.

Los datos de mercado se obtienen mediante *yfinance*[3], una biblioteca de Python que permite acceder a datos públicos de Yahoo Finance. Gracias a esta librería se obtienen los precios ajustados, volumen negociado y la serie del ETF SPY, utilizada como referencia para comparar los resultados del modelo. A partir de esta información se generan variables que resumen el comportamiento de cada activo, como retornos, volatilidad, *momentum* y señales relacionadas con el volumen. Junto a estas variables del activo, también se incorporan señales agregadas del mercado. El agente no observa únicamente la evolución individual de cada activo, sino también una visión amplia del comportamiento del mercado.

Además de la información propia de los activos, el estado también está formado por las variables de contexto exógeno de carácter macro financiero, obtenidas a partir de FRED, la base de datos económica del Banco de la Reserva Federal de St. Louis[4]. Estas variables representan condiciones generales del entorno en el que se toman las decisiones de inversión. Entre ellas se incluyen los tipos de interés, inflación, desempleo, volatilidad agregada, precio del petróleo o tipo de cambio[5]. La incorporación de este bloque tiene como objetivo que el modelo no dependa solo de las señales internas del mercado, sino que también considere factores externos que influyen en el comportamiento general de los activos.

Para poder combinar todas estas fuentes de información, es necesario alinear sobre un mismo calendario temporal ya que los datos de mercado tienen frecuencia diaria, mientras que algunas variables macro financieras pueden publicarse con menor frecuencia o en fechas distintas. Por eso, cuando una variable externa no tiene un nuevo dato disponible para un día determinado, se mantiene el último valor conocido hasta que aparece una nueva observación. Además, al contexto exógeno se le aplica un desfase de un día para reducir el riesgo de usar información que no estaría disponible en el momento de decidir. También se generan variables derivadas que representan mejor el entorno económico, como cambios recientes en la inflación, movimientos en los tipos de interés o variaciones del VIX (*Volatility Index*), un indicador de volatilidad esperada en el mercado estadounidense. Estas variables se obtienen a partir del valor observado de cada indicador, ya que se calculan cambios o variaciones en distintos periodos gracias a las series originales.

[3] yfinance: biblioteca de Python disponible en PyPI para la descarga de datos financieros procedentes de Yahoo Finance. https://pypi.org/project/yfinance/

[4] FRED: base de datos económica mantenida por el Banco de la Reserva Federal de St. Louis. https://fred.stlouisfed.org/

[5] Los indicadores de tipos de interés, inflación, desempleo, volatilidad agregada, petróleo y tipo de cambio se descargan mediante los identificadores definidos en la configuración del experimento. La documentación de la API utilizada para acceder a estas series está disponible en: https://fred.stlouisfed.org/docs/api/fred/

La normalización de las variables también se realiza respetando la separación temporal del experimento, de forma que entren al modelo en escalas comparables. Este paso es necesario porque el estado combina datos muy distintos entre sí, como retornos, volumen, tipos de interés o variables macroeconómicas. Para evitar que una variable tenga más peso solo por tener valores numéricamente mayores, se transforman sus valores antes del entrenamiento. Además, se calcula únicamente con los datos de entrenamiento de cada ventana y después se aplica a validación y test sin volver a ajustarla. De esta manera, el modelo trabaja con datos estables sin utilizar información de periodos posteriores.

Con estas etapas, toda la información anterior queda organizada dentro del estado observado $s_t$. Este estado agrupa, por un lado, las variables de mercado construidas a partir de precios ajustados y volumen, como retornos, volatilidad, *momentum* y señales asociadas a la negociación de cada activo. Por otro lado, incorpora los pesos actuales de la cartera, que indican desde qué asignación parte el agente antes de proponer un nuevo ajuste. Junto a ello, se añaden señales auxiliares $f_t$, que resumen el comportamiento agregado del mercado, entre ellas se incluyen la volatilidad media del universo de activos, la relación entre los movimientos de los activos y la evolución del ETF SPY, utilizado como referencia del comportamiento general del mercado estadounidense. Finalmente, el estado incluye el contexto exógeno macro financiero procedente de FRED, junto con la información asociada al régimen de mercado. De forma compacta, el estado puede expresarse como:

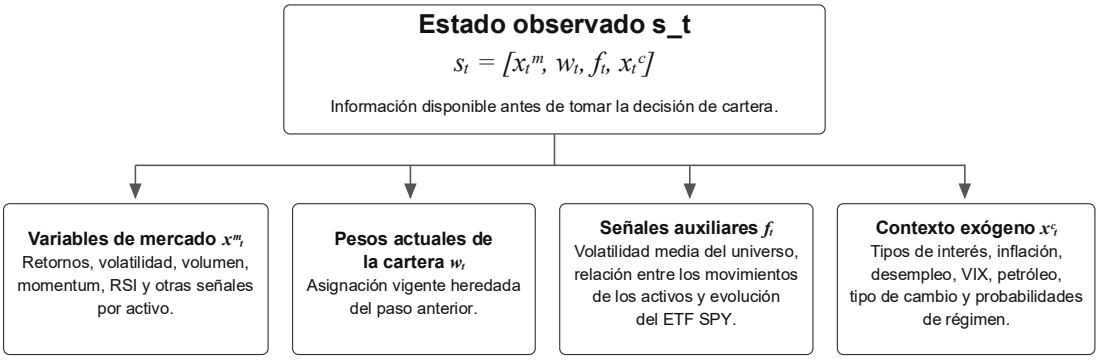



***Figura 4.2.*** *Descomposición conceptual del estado observado en bloques de mercado, estado heredado de la cartera y contexto exógeno. Elaboración propia.*

## 4.3 Arquitectura de representación y modulación contextual

Una vez definido el estado observado $s_t$, la arquitectura diferencia el procesamiento de la información en dos bloques principales: una orientada a la información de mercado y de cartera, y otra centrada en el contexto externo macro financiero. Esta separación es necesaria porque permite tratar de forma distinta señales que tienen naturaleza diferente antes de combinarlas en una representación común. La Figura 4.3 muestra cómo es la arquitectura de representación e integración contextual.

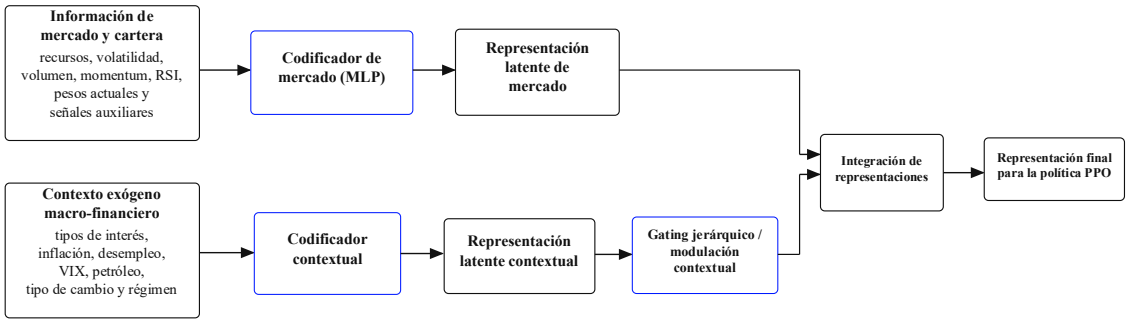



***Figura 4.3.*** *Esquema del mecanismo de gating jerárquico utilizado para modular la contribución del contexto exógeno sobre la representación final del estado. Elaboración propia.*

La rama de mercado procesa la información relacionada directamente con los activos y con la cartera vigente. Su función es obtener una representación interna del comportamiento del universo de inversión y de la posición desde la que parte el agente antes de tomar una nueva decisión. Es importante entender que esta representación no añade una fuente de datos nueva, sino que transforma la información disponible en una forma útil para la política.

La segunda rama se encarga de procesar el contexto exógeno macro financiero. Este bloque recoge información externa al comportamiento individual de los activos. Su función es resumir las condiciones generales del entorno económico y financiero en el que se toma la decisión de cartera. De esta manera, la arquitectura no solo representa el comportamiento de los activos dentro del universo de inversión, sino también el contexto externo que puede influir en su comportamiento.

Para transformar ambas ramas en representaciones utilizables por la política, el modelo emplea codificadores neuronales de tipo MLP (*Multilayer Perceptron*). Un codificador de este tipo es una red neuronal sencilla formada por varias capas que recibe variables de entrada y las transforma en una representación interna. Esta representación se entiende como un vector numérico que resume los patrones relevantes de cada bloque de información. En este caso, el codificador de mercado recibe señales como retornos, volatilidad, volumen, pesos actuales de la cartera y variables auxiliares de mercado. En lugar de trasladar toda esa información de forma dispersa a la política, la resume en un vector interno que representa el estado del universo de inversión y de la cartera. De forma paralela, el codificador contextual procesa las variables de contexto y genera otro vector que resume el entorno macro financiero. Estos vectores no son nuevas variables financieras, sino representaciones aprendidas por la red para que después puedan ser integrados.

La elección de modelos MLP es debido a que el estado que recibe el agente no está formado por precios brutos, sino por variables financieras ya preparadas. Por lo que el modelo ya recibe una descripción resumida del mercado y situación de cartera. Por eso, se ha considerado que un MLP encaja bien en este trabajo ya que funciona como una red

que aprende a combinar muchas variables de entrada para obtener una decisión. Al contrario de otras arquitecturas, su función no es descubrir desde cero la evolución de los precios, sino aprender a combinar toda esa información ya preparada para tomar una decisión.

Otras arquitecturas tendrían más sentido si fuera otro tipo de entrada. Una CNN sería útil en el caso de trabajar con una matriz de precios o indicadores, buscando patrones entre activos o entre días cercanos. Una RNN o una LSTM serían más adecuadas si el modelo recibiera directamente una secuencia de precios día a día; en este trabajo, en cambio, esa información temporal ya se resume antes mediante variables como retornos, volatilidad o *momentum*, por lo que no es necesario que la red aprenda toda la secuencia desde cero. Un *Transformer* sería útil si el modelo tuviera que analizar muchas relaciones a la vez entre distintos momentos temporales o entre muchas variables, dando más importancia a unas partes de la información que a otras. En este trabajo, sin embargo, se busca una arquitectura más sencilla y estable, porque el estado ya resume la información principal del mercado y además el mecanismo de *gating* ya introduce una forma específica de decidir cuánto debe influir el contexto externo.

Por ello, la integración entre ambas ramas se realiza mediante un mecanismo de *gating* jerárquico. En este trabajo, el *gating* puede entenderse como una compuerta aprendida que regula la influencia del contexto exógeno antes de combinarlo con la información de mercado. La idea es que el contexto macro financiero no tiene por qué ser igual de útil en todos los periodos: en algunos momentos puede aportar información relevante y en otros introducir ruido. Por ello, el modelo aprende a ajustar su importancia antes de generar la representación final utilizada por la política. Se denomina jerárquico porque esta modulación se realiza en más de un nivel. En primer lugar, el modelo calcula una compuerta que decide cuánta relevancia debe tener el contexto externo en ese instante. Este primer nivel responde a una pregunta general: cuánto debe influir el contexto macro financiero en la decisión. Después de decidir la importancia general del contexto, el modelo realiza un segundo ajuste más detallado. En este nivel no trata todo el contexto como un bloque único, sino que regula su efecto dentro de la representación interna. Es decir, puede reforzar algunas señales contextuales y reducir otros antes de combinarlas con la información de mercado. De esta forma, el sistema no solo decide cuánto contexto utilizar, sino también cómo hacerlo entrar en la representación final que después usará la política PPO.

Este planteamiento se relaciona con trabajos del estado del arte que utilizan mecanismos de atención, *gating* o modulación para combinar información de distinta naturaleza. Por ejemplo, algunos enfoques basados en atención permiten que el modelo asigne más peso a determinadas señales, mientras que otros mecanismos de modulación, como los usados en arquitecturas como *FiLM, Squeeze-and-Excitation* o *CBAM*, buscan regular la contribución de ciertas representaciones internas. En finanzas, también existen trabajos recientes que exploran mecanismos de *gating* o atención para gestionar información heterogénea en entornos no estacionarios. Sin embargo, la propuesta de este trabajo se

diferencia en que el contexto macro financiero no se incorpora simplemente como una variable adicional dentro del estado, sino que se procesa en una rama específica y se modula antes de integrarse con la representación de mercado.

La representación final obtenida tras la modulación es la que recibe la política PPO para generar una acción incremental sobre la cartera vigente. Posteriormente, esa propuesta se somete a los mecanismos de control operativo y seguridad descritos en los apartados siguientes. De este modo, la arquitectura conecta la representación del entorno con la decisión de inversión y con su posterior ejecución controlada.

## 4.4 Política PPO y acción incremental

La representación final obtenida tras la integración de la información de mercado y del contexto exógeno es la entrada que utiliza la política PPO para tomar la decisión de cartera. Como se ha mencionado, el modelo ya no trabaja con cada variable por separado, sino con una representación interna que resume el estado observado. A partir de esa representación, la política genera una acción continua. Esto significa que la salida del modelo no es una categoría cerrada, como elegir un único activo o seleccionar entre comprar, vender o mantener, sino un conjunto de valores numéricos asociados a los activos de la cartera. Estos valores indican en qué dirección y con qué intensidad debe modificarse la asignación actual. Por ejemplo, la política puede sugerir aumentar ligeramente el peso de unos activos, reducir el de otros y mantener el resto prácticamente sin cambios. Esta forma de decisión encaja mejor con el problema de cartera, donde la decisión consiste en ajustar proporciones de capital.

En la implementación del modelo, la política genera una señal numérica para cada activo. Por tanto, si la cartera está formada por $N$ activos, la acción puede entenderse como un vector con $N$ componentes, donde cada componente representa el ajuste propuesto sobre un activo concreto. En este trabajo, al utilizarse un universo de 100 activos, la política genera una señal de ajuste para cada uno de ellos. Esa señal no se interpreta todavía como el peso final de la cartera, sino como una indicación previa que después se traduce en una modificación incremental de los pesos vigentes.

En la práctica, los valores de la acción están acotados entre $-1$ y $1$. Un valor positivo tiende a aumentar el peso del activo correspondiente, mientras que un valor negativo tiende a reducirlo. Antes de convertirse en una modificación de cartera, esta señal se interpreta de forma relativa entre activos: aquellos con señales más altas tienden a ganar peso y aquellos con señales más bajas tienden a reducirlo. Como la cartera debe seguir repartiendo el total del capital disponible, los aumentos de peso en unos activos se compensan con reducciones en otros. De esta forma, la política no fija directamente los porcentajes finales, sino que indica la dirección del ajuste sobre la cartera actual. Como se indicó en la expresión (2.20), la acción incremental se define como:

$$w_t^{tar} = w_t + \Delta w_t(a_t)$$

En el modelo propuesto, esta formulación permite que la política entrenada por PPO no tenga que construir la cartera completa desde cero en cada fecha. La acción $a_t$ es la señal numérica generada por la política para los activos: indica qué posiciones tienden a aumentar peso y cuáles tienden a reducirlo según el estado observado. Esta acción no se aplica directamente como una cartera final, sino que se transforma en un cambio de pesos $\Delta w_t(a_t)$. Con ese cambio, la cartera vigente se desplaza hacia una nueva asignación preliminar, llamada cartera objetivo $w_t^{tar}$. Esta cartera representa la primera propuesta del agente, pero todavía no es la asignación final que se ejecuta, ya que después debe pasar por los mecanismos de control operativo y seguridad.

## 4.5 Control operativo y ejecución segura

La cartera objetivo $w_t^{tar}$, obtenida a partir de la acción incremental de la política, como ya se ha señalado anteriormente, no es la cartera ejecutada final. Aunque esta cartera representa la primera propuesta del agente, todavía puede implicar un cambio muy brusco respecto a la cartera actual o quedar fuera de las restricciones planteadas para el problema. Por ello, el modelo incorpora un bloque de ejecución que actúa entre la decisión de la política y la cartera ejecutada. Su función es que la propuesta inicial del agente sea una asignación más estable y válida desde el punto de vista operativo. Este bloque se organiza en dos etapas: primero se aplica un control de rebalanceo y después, se aplica una capa de seguridad encargada de garantizar que la cartera final cumpla las restricciones del modelo.

El primer paso del bloque de ejecución consiste en controlar la intensidad del rebalanceo. Para ello, el sistema compara la cartera objetivo o $w_t^{tar}$ con la cartera vigente $w_t$ y calcula el cambio necesario para pasar de una asignación a otra. En lugar de sustituir directamente la cartera actual por la cartera objetivo, el sistema puede desplazarse a ella de forma parcial. Es decir, toma la diferencia entre ambas carteras y aplica solo una parte de ese cambio. De esta manera, si la propuesta del agente implica mover demasiado capital entre activos, el rebalanceo se suaviza antes de continuar con la ejecución.

Este ajuste puede expresarse mediante la relación ya introducida en el marco teórico, la expresión (2.21):

$$w_t^{prop} = w_t + \alpha_t(w_t^{tar} - w_t)$$

donde $w_t^{prop}$ representa la cartera propuesta tras el control de rebalanceo y $\alpha_t$ indica qué proporción del cambio se aplica en ese instante. Si $\alpha_t = 1$, el sistema aplica todo el ajuste sugerido por el agente; si $\alpha_t < 1$, solo aplica una parte y la cartera se mueve de forma más gradual hacia la cartera objetivo.

En el modelo propuesto, el control de rebalanceo se adapta al estado del mercado. La idea es que no tiene el mismo sentido aplicar un cambio grande cuando el entorno está estable que cuando el mercado muestra señales de tensión. Por eso, el sistema utiliza información

como la probabilidad de régimen de estrés, la volatilidad agregada y la correlación media entre activos para decidir cuánto suavizar el ajuste propuesto por la política. Si el entorno parece más inestable, el rebalanceo se vuelve más prudente y permite mover menos peso entre activos. Así, la decisión no depende solo de lo que propone PPO, sino también de las condiciones en las que esa propuesta se va a ejecutar.

Tras aplicar el control de rebalanceo se obtiene la cartera propuesta $w_t^{prop}$. Esta cartera recoge el ajuste del agente, pero de una forma más moderada respecto a la cartera objetivo inicial. Aun así, todavía es necesario comprobar que sus pesos cumplen todas las restricciones del modelo. Por eso, el siguiente paso consiste en aplicar una capa de seguridad, cuyo objetivo es convertir esa propuesta en una cartera válida y finalmente ejecutable.

La capa de seguridad se implementa mediante una proyección convexa, formulada como un problema cuadrático. Su objetivo es encontrar la cartera válida más cercana posible a la cartera propuesta $w_t^{prop}$. De esta forma, si la propuesta ya cumple las restricciones, apenas se modifica; pero si algún peso queda fuera de los límites permitidos, el sistema realiza el ajuste mínimo necesario para obtener una cartera factible. En este trabajo, las restricciones principales son que la suma de los pesos sea igual a uno, que no existan posiciones negativas y que ningún activo supere el peso máximo permitido.

En la configuración del modelo, este límite se fija en $w_{\max} = 0{,}10$, de forma que ningún activo pueda concentrar más del 10 % del capital de la cartera. La idea es evitar que el agente concentre demasiado la inversión en unos pocos activos, porque una cartera muy concentrada puede volverse más dependiente del comportamiento de esas posiciones concretas. Al mismo tiempo, el límite del 10 % deja cierto margen para que el modelo asigne más peso a los activos que considere más interesantes según el estado observado. Por tanto, no se utiliza como un valor óptimo universal, sino como una restricción operativa prudente para favorecer la diversificación. Además, este umbral está alineado con referencias habituales de control de concentración, como la regla 5/10/40 de UCITS, que permite elevar el límite por emisor hasta el 10 % bajo determinadas condiciones de diversificación (European Parliament and Council, 2009; ESMA, s. f.).

En la implementación, la proyección convexa se formula mediante CVXPY y se resuelve con OSQP. CVXPY es una librería de Python que permite escribir problemas de optimización de forma estructurada, indicando qué variable se quiere encontrar, qué objetivo se quiere minimizar y qué restricciones deben cumplirse. En este caso, la variable que se busca es el vector final de pesos de la cartera. El objetivo es que ese vector se parezca lo máximo posible a la cartera propuesta $w_t^{prop}$, pero cumpliendo las condiciones necesarias para que sea válida.

Una vez formulado el problema, OSQP es el *solver* que se encarga de resolverlo numéricamente. Es decir, calcula qué combinación de pesos cumple las restricciones y, al mismo tiempo, queda lo más cerca posible de la propuesta inicial. Su uso encaja con este modelo porque el problema se plantea como una optimización cuadrática.

El resultado de esta proyección es la cartera ejecutada $w_t^{exec}$, que es la asignación que finalmente se aplica en el entorno. Esta cartera mantiene, en la medida de lo posible, la propuesta generada por el agente, pero ajustada para cumplir las restricciones del modelo. Por tanto, la capa de seguridad no sustituye la decisión de la política PPO, sino que actúa como una corrección final cuando la propuesta no es directamente ejecutable. A partir de $w_t^{exec}$, el sistema calcula el rendimiento obtenido en el siguiente periodo y actualiza la cartera para continuar con el siguiente paso del ciclo.

## 4.6 Función de recompensa

Una vez obtenida la cartera ejecutada $w_t^{exec}$, el entorno calcula el resultado económico del siguiente periodo y, a partir de él, la recompensa que recibirá el agente. Esta recompensa es la señal que guía el aprendizaje de la política PPO, ya que indica qué decisiones han sido favorables y cuáles deberían evitarse en situaciones similares. Por ello, su diseño es importante: no solo debe premiar la rentabilidad, sino también orientar al agente hacia decisiones estables y controladas desde el punto de vista del riesgo.

La recompensa del modelo se construye a partir de cuatro elementos principales: el retorno neto de la cartera $R_{p,t+1}^{net}$, la rotación generada por el rebalanceo $TO_{t+1}$, el componente asociado a pérdidas $L_{t+1}$ y el incremento del drawdown $\Delta DD_{t+1}$. Con esta estructura, el agente no aprende solo a buscar rentabilidad en un periodo concreto, sino también a tener en cuenta cuánto ha tenido que mover la cartera y si esa decisión ha aumentado el riesgo o ha empeorado la trayectoria. Siguiendo la formulación introducida en el marco teórico, en la expresión (2.23), la recompensa puede expresarse de forma compacta como:

$$\rho_{t+1} = F(R_{p,t+1}^{net}, TO_{t+1}, L_{t+1}, \Delta DD_{t+1})$$

En la implementación, la recompensa se calcula siempre a partir de la cartera finalmente ejecutada $w_t^{exec}$, no a partir de la cartera objetivo inicial. Primero se calcula cómo se habría comportado la cartera ejecutada $w_t^{exec}$ en el periodo siguiente. Para ello, se toman los pesos finalmente aplicados y se combinan con los retornos observados de los activos entre $t$ y $t+1$, esto es necesario ya que todavía no se conoce si la decisión ha sido buena o no, se debe esperar a observar qué ocurre después en el mercado. El resultado de este cálculo es el rendimiento bruto de la cartera, es decir, la ganancia o pérdida antes de descontar los costes asociados a las operaciones.

A continuación, se descuentan las fricciones generadas por el rebalanceo. En el modelo se consideran dos componentes: el coste de transacción y el *slippage* (deslizamiento de ejecución). El coste de transacción representa el gasto asociado a comprar y vender activos. El *slippage*, en cambio, aproxima la diferencia que puede aparecer entre el precio esperado de una operación y el precio al que finalmente se ejecuta. Una vez descontados ambos elementos, se obtiene el retorno neto $R_{p,t+1}^{net}$, que refleja el rendimiento efectivo de la decisión tomada por el agente.

En la configuración experimental, el coste de transacción se fija en 0.001 y el *slippage* en 0.0005 por unidad de rotación, equivalentes a 10 y 5 puntos básicos, respectivamente. Estos valores se consideran costes pequeños, pero distintos de cero. Son razonables para un universo formado por activos líquidos del S&P 500 y están en línea con supuestos utilizados en trabajos de gestión de carteras y *backtesting* sobre renta variable estadounidense (Jin & El-Saawy, 2016; Avellaneda & Lee, 2010). De este modo, el modelo no trata el rebalanceo como si fuera gratuito, pero tampoco permite que los costes tengan más peso que la propia señal de rentabilidad.

Además del retorno neto, la recompensa incluye una penalización por la rotación de la cartera. La rotación indica cuánto cambia la composición de la cartera respecto al periodo anterior. Este término es importante porque una estrategia puede parecer rentable si cambia mucho sus posiciones, pero en la práctica esos cambios generan costes y pueden hacer que parte de la rentabilidad obtenida se pierda al operar. Por eso, cuando el agente propone movimientos demasiado grandes entre activos, la recompensa se reduce. Así, PPO aprende que no solo debe buscar rentabilidad, sino también evitar rebalanceos grandes que puedan deteriorar el resultado final.

La recompensa también incluye un componente asociado a las pérdidas. Su función es hacer que el modelo sea más sensible a los periodos negativos, ya que en una cartera no tiene el mismo efecto una pequeña ganancia que una pérdida de la misma magnitud. Las caídas reducen el valor acumulado de la cartera y pueden afectar a su estabilidad, por lo que el modelo las penaliza de forma adicional cuando el retorno neto del periodo es negativo. Con ello, la política no aprende únicamente a buscar rentabilidad, sino también a evitar decisiones que puedan provocar pérdidas relevantes.

El último componente de la recompensa está relacionado con el incremento del *drawdown*. Mientras que el término de pérdidas se centra en el resultado negativo de un periodo concreto, el *drawdown* mide el deterioro acumulado de la cartera respecto a su máximo valor anterior. Por eso, cuando una decisión hace que la cartera profundice su caída, la recompensa introduce una penalización adicional. Este término ayuda a que el agente tenga en cuenta no solo el rendimiento inmediato, sino también la trayectoria seguida por la cartera a lo largo del tiempo.

En conjunto, esta función de recompensa busca equilibrar varios objetivos financieros dentro del aprendizaje. El agente recibe una señal positiva cuando la cartera obtiene rendimiento neto, pero esa señal se reduce si la decisión exige demasiada rotación, genera pérdidas o aumenta el deterioro acumulado de la cartera. A continuación, para resumir el papel de cada elemento dentro de la función de recompensa, la Tabla 4.1 recoge sus principales componentes y la función que desempeñan en el aprendizaje del agente.

| Componente | Qué mide | Papel en la recompensa |
|---|---|---|
| **Retorno neto $R_{pt+1}^{net}$** | Rendimiento de la cartera ejecutada después de descontar costes de transacción y deslizamiento de ejecución. | Premia las decisiones que generan rentabilidad efectiva. |
| **Rotación $TO_{t+1}$** | Cambio realizado en los pesos de la cartera entre dos periodos consecutivos. | Penaliza rebalanceos excesivos y ayuda a reducir costes operativos. |
| **Pérdidas $L_{t+1}$** | Parte negativa del retorno neto cuando el resultado del periodo es desfavorable. | Hace que el modelo sea más sensible a caídas y decisiones con pérdidas. |
| **Incremento del drawdown $\Delta DD_{t+1}$** | Aumento de la caída acumulada respecto al máximo previo de la cartera. | Penaliza el deterioro de la trayectoria y favorece estrategias más estables. |

***Tabla 4.1.*** *Componentes de la función de recompensa del modelo propuesto. Elaboración propia*

## 4.7 Configuración final del modelo

En conjunto, el modelo propuesto se organiza como un flujo secuencial que transforma el estado observado en una decisión de cartera y, posteriormente, en una asignación ejecutable. La información de mercado y el contexto exógeno se procesan mediante ramas diferenciadas, el mecanismo de *gating* regula la influencia del contexto y la política PPO genera una acción incremental sobre la cartera vigente. A partir de esa acción se obtiene una cartera objetivo, que después pasa por los mecanismos de control de rebalanceo y seguridad antes de ser ejecutada.

Una vez aplicada la cartera ejecutada, el entorno observa los retornos del periodo siguiente y calcula la recompensa correspondiente. Esta recompensa recoge no solo el rendimiento neto obtenido, sino también la rotación, las pérdidas y el deterioro acumulado de la trayectoria. Con ello, el sistema actualiza la información disponible y avanza al siguiente estado $s_{t+1}$, cerrando así el ciclo de decisión, ejecución y aprendizaje.

De esta forma, la propuesta combina en un mismo sistema la generación de decisiones mediante aprendizaje por refuerzo, la incorporación modulada de contexto exógeno y una fase final de control operativo. Esta separación entre decisión y ejecución permite que el agente aprenda a proponer cambios de cartera, mientras que el bloque de seguridad garantiza que la asignación finalmente aplicada sea coherente con las restricciones del problema.

# Capítulo 5. Experimentación, resultados y discusión

## 5.1 Configuración de la evaluación

En este capítulo se evalúa el sistema final propuesto, denominado en el proyecto como **PPO_gated_full**, frente a un conjunto de estrategias clásicas de referencia. La evaluación se realiza sobre el mismo universo de activos, periodo temporal y restricciones ya descritas en el Capítulo 4. Este apartado se centra en resumir el protocolo experimental utilizado para obtener los resultados.

La evaluación se organiza mediante un esquema walk-forward. En cada ventana, el modelo se entrena con cuatro años de datos, se valida durante el año siguiente y se prueba en el año posterior. Después, la ventana se desplaza seis meses y el proceso se repite. Con esta configuración se obtienen 13 ventanas de evaluación, lo que permite analizar el comportamiento del modelo en distintos periodos de mercado sin alterar el orden temporal de los datos.

En todas las ventanas se mantienen las mismas condiciones generales de evaluación: frecuencia diaria, costes de transacción de 0.001, *slippage* de 0.0005 y las restricciones de cartera definidas previamente. Todas las estrategias comparadas se evalúan sobre las mismas ventanas temporales y con las mismas métricas, de forma que los resultados sean comparables entre sí.

El entrenamiento del modelo se ha realizado en un equipo con procesador 11th Gen Intel(R) Core(TM) i5-1135G7 @ 2.40GHz, 16 GB de memoria RAM y sistema operativo Microsoft Windows 11 Pro de 64 bits. Aunque el equipo dispone de tarjeta gráfica integrada Intel(R) Iris(R) Xe Graphics, el entrenamiento se realizó mediante CPU, ya que no se ha utilizado una tarjeta gráfica dedicada para acelerar el proceso. Cada ventana tardó aproximadamente 1 hora y 10 minutos en completarse, por lo que el proceso completo de entrenamiento del modelo final tuvo una duración aproximada de 15 horas.

Es importante señalar que las estrategias clásicas de referencia no son modelos entrenados. El único modelo que se entrena como agente por aprendizaje por refuerzo es **PPO_gated_full**. El resto se basa en reglas o criterios clásicos de asignación, que se aplican directamente sobre los datos de cada ventana temporal. Todas ellas se evalúan sobre los mismos periodos de prueba, con los mismos costes de transacción, las mismas restricciones y las mismas métricas, para que la comparación sea homogénea.

La configuración del experimento se define en los archivos de configuración del proyecto, y la creación de las ventanas temporales se realiza mediante el módulo encargado del procedimiento *walk-forward.*

| Parámetro | Valor |
|---|---|
| Modelo evaluado | PPO_gated_full |
| Periodo total | 01-01-2010 a 31-12-2024 |
| Universo de inversión | 100 activos del S&P 500 |
| Frecuencia de los datos | Diaria |
| Protocolo de evaluación | Walk-forward |
| Entrenamiento por ventana | 4 años |
| Validación por ventana | 1 año |
| Prueba por ventana | 1 año |
| Desplazamiento entre ventanas | 6 meses |
| Número de ventanas | 13 |
| Coste de transacción | 0.001 |
| Slippage | 0.0005 |
| Restricciones de cartera | Posiciones largas, inversión completa del capital y peso máximo del 10 % por activo |

***Tabla 5.1.*** *Resumen de la configuración experimental utilizada en la evaluación. Elaboración propia a partir de la configuración del proyecto.*

## 5.2 Métricas utilizadas

Las métricas utilizadas en la evaluación ya han sido introducidas en el marco teórico, por lo que en este apartado se explicará como criterios de lectura para los resultados. El objetivo de utilizar distintas métricas es debido a que cada estrategia puede tener distintos enfoques, donde no siempre están orientadas a maximizar la rentabilidad. Algunas buscan mejorar la relación entre rentabilidad y riesgo, otras reducir las caídas acumuladas y otras limitar la rotación o los costes de operación. Por esta razón, la evaluación no se basa en una única medida, sino en un conjunto de indicadores que permite valorar el comportamiento global de cada estrategia.

En primer lugar, el CAGR permite observar cuánto habría crecido la cartera de media cada año durante el periodo evaluado. Esta métrica es muy útil para comparar la rentabilidad obtenida por cada estrategia, pero no se tiene en cuenta el riesgo asumido para conseguirla. Por ello, se complementa con el ratio de Sharpe y el ratio de Calmar. El Sharpe compara la rentabilidad con la volatilidad de los retornos, mientras que el Calmar la compara con la máxima caída acumulada de la cartera. De esta forma, ambas métricas permiten analizar la rentabilidad ajustada al riesgo, pero desde perspectivas distintas.

En segundo lugar, el *Max Drawdown* y el CVaR al 95 % se utilizan para analizar cómo se comportan las estrategias cuando aparecen pérdidas. El *Max Drawdown* muestra la mayor caída acumulada que sufre la cartera desde un máximo anterior, por lo que ayuda a entender hasta dónde puede llegar a caer su valor durante el periodo evaluado. El CVaR al 95 %, en cambio, se centra en los peores resultados diarios y resume la pérdida media dentro de ese grupo más desfavorable. Así, la evaluación no se limita a medir el

rendimiento medio, sino que también tiene en cuenta cómo responde cada estrategia ante situaciones negativas o de mayor tensión.

Por último, el turnover medio y el coste total permiten analizar la parte operativa de cada estrategia. Estas métricas son importantes porque una cartera puede obtener buenos resultados antes de costes, pero perder parte de esa rentabilidad si necesita cambiar sus posiciones con demasiada frecuencia. En este trabajo son especialmente relevantes, ya que el modelo final incorpora mecanismos de control orientados a evitar cambios excesivos en la composición de la cartera.

| Bloque de análisis | Métricas | Interpretación de los valores |
|---|---|---|
| Rentabilidad | CAGR | Valores más altos indican mayor crecimiento anual medio de la cartera. |
| Rentabilidad ajustada al riesgo | Sharpe, Calmar | Valores más altos indican una mejor relación entre la rentabilidad obtenida y el riesgo asumido. |
| Riesgo de pérdidas | Max Drawdown, CVaR 95 % | Valores menos negativos indican menor exposición a caídas importantes o pérdidas extremas. |
| Estabilidad operativa | Turnover medio, coste total | Valores más bajos indican una operativa más estable y un menor impacto de los costes de operación. |

***Tabla 5.2.*** *Interpretación de las métricas utilizadas en la evaluación. Elaboración propia.*

## 5.3 Resultados globales

Los resultados que se muestran a continuación se obtienen a partir de las ejecuciones del proyecto. En cada ventana temporal, el modelo se entrena con el bloque de entrenamiento, se valida con el bloque correspondiente y después se prueba en el periodo reservado para test. Sobre ese mismo periodo de prueba se aplican también las estrategias clásicas, siguiendo sus criterios de asignación. Los resultados por ventana y los resúmenes globales se guardan en ficheros CSV dentro de la carpeta de resultados del proyecto. Por tanto, las tablas de este capítulo proceden directamente de las ejecuciones realizadas.

| Estrategia | Sharpe | CAGR (%) | MaxDD (%) | Calmar | CVaR 95% | Turnover | Coste |
|---|---|---|---|---|---|---|---|
| **PPO_gated_full** | 0.990 | 16.21 | 15.51 | **2.324** | 42.37 | 2.13 | 0.80 |
| EqualWeight | **1.096** | **18.96** | 15.82 | 2.268 | 43.61 | **0.00** | **0.00** |
| InverseVolatility | 1.068 | 16.86 | 14.94 | 2.111 | 40.50 | 0.63 | 0.24 |
| Buy&Hold Index | 0.958 | 15.58 | 16.91 | 1.895 | 43.63 | **0.00** | **0.00** |
| MeanVariance | 0.767 | 15.32 | 15.66 | 1.522 | 43.38 | 5.85 | 2.21 |
| MinimumVariance | 0.759 | 9.90 | **12.86** | 1.417 | **32.42** | 2.97 | 1.12 |

***Tabla 5.3**. Resultados globales de las estrategias evaluadas. Elaboración propia.*

La Tabla 5.3 recoge los resultados globales obtenidos por el modelo y la comparativa con las estrategias de referencia clásicas. Son los datos obtenidos a partir de las métricas obtenidas de las trece ventanas temporales del procedimiento *walk-forward* y se resume mediante su media. Por ello, la tabla muestra el rendimiento general de cada estrategia general antes de analizar, en el siguiente apartado, la comparativa en distintos periodos. La comparación, como ya se ha mencionado, trata de analizar tanto la rentabilidad como la relación entre rentabilidad y riesgo, las caídas acumuladas y el impacto operativo.

En términos de rentabilidad ajustada al riesgo, observamos que el modelo propuesto **PPO_gated_full** obtiene un valor en el ratio Sharpe de 0.990. Este resultado queda por debajo de *Equal Weight* e *Inverse Volatility*, que alcanzan 1.096 y 1.068 respectivamente, pero supera a *Buy And Hold Index, Mean Variance* y *Minimum Variance.* Este punto es interesante porque *Mean Variance* y *Minimum Variance* son estrategias clásicas de optimización de carteras basadas en el riesgo estimado, por lo que quedar por encima de ellas indica que el modelo dinámico logra una relación competitiva entre rentabilidad y variabilidad. Al mismo tiempo, *Equal Weight* e *Inverse Volatility* muestran que las estrategias sencillas pueden ser difíciles de superar. Al mantener reglas de asignación más estables y menos sensibles a cambios de mercado, estas estrategias consiguen funcionar muy bien en determinados periodos. Aun así, el modelo propuesto no queda alejado de las mejores referencias y se mantiene en un rango competitivo dentro de esta comparativa global. En cuanto al CAGR, el modelo alcanza un 16.21 %, por debajo de *Equal Weight* e *Inverse Volatility,* que obtienen un 18.96 % y un 16.86 % respectivamente, y por encima de *Buy And Hold Index, Mean Variance* y *Minimum Variance,* que alcanzan un 15,58 %, un 15.32 % y un 9.90 % respectivamente. Esto resulta relevante porque el modelo no está diseñado únicamente para maximizar la rentabilidad, sino también para tomar decisiones dinámicas bajo costes, restricciones y control de rebalanceo. De esta forma, el CAGR obtenido muestra una buena capacidad de crecimiento sin dejar el enfoque de control incorporado.

Al observar el *Max Drawdown,* el modelo obtiene una caída máxima del 15.51 %. Este valor es muy cercano al de *Equal Weight*, con un 15.82 %, y al de *Mean Variance*, con un 15.66 %, y mejora el resultado de *Buy And Hold Index*, que alcanza un 16.91 %, algo esperable al tratarse de una estrategia pasiva que mantiene la exposición al mercado durante todo el periodo. Sin embargo, *Inverse Volatility* y *Minimum Variance* presentan

caídas menores, con un 14.94 % y un 12.86 %, respectivamente. Por tanto, el modelo final no es la estrategia con menor caída máxima, pero mantiene un nivel de *drawdown* competitivo dentro de la comparativa. Esto significa que el modelo no elimina por completo las caídas fuertes, pero consigue mantenerlas en un rango similar al de varias estrategias de referencia, sin sacrificar de forma excesiva la capacidad de crecimiento observada en el CAGR.

El resultado donde destaca el modelo se observa en el ratio de Calmar. En esta métrica **PPO_gated_full** obtiene el mejor valor de toda la comparativa con 2.324. El resultado resulta muy relevante porque el ratio de Calmar relaciona el crecimiento anual de cartera con su máxima caída acumulada. Por tanto, aunque el modelo no alcanza el mayor CAGR ni la menor caída máxima, sí consigue la mejor relación entre estas dos. Esta métrica resulta útil para interpretar el comportamiento del modelo, ya que el resultado de Calmar sugiere que el modelo consigue transformar una rentabilidad elevada en un perfil de riesgo más equilibrado. Esta lectura encaja con el diseño de la propuesta, que no busca únicamente aumentar el rendimiento, sino también controlar el deterioro de la cartera mediante mecanismos de seguridad, penalización de pérdidas y control del rebalanceo.

En el CVaR al 95 %, el sistema obtiene un valor de 42.37 %. Esta métrica permite observar qué ocurre en los peores resultados diarios, por lo que valores más bajos indican menor exposición a pérdidas extremas. En este caso, *Minimum Variance* e *Inverse Volatility* obtienen mejores resultados, con un 32.42 % y un 40.50 %, respectivamente. Esto tiene sentido, ya que *Minimum Variance* está orientada a reducir el riesgo de la cartera, mientras que *Inverse Volatility* tiende a dar más peso a los activos que han mostrado menor volatilidad. Aun así, el modelo mejora los resultados de *Equal Weight, Buy And Hold Index* y *Mean Variance*. Este último caso resulta interesante porque *Mean Variance* también incorpora el riesgo dentro de su criterio de optimización, pero en esta evaluación no consigue un comportamiento más favorable en los escenarios más adversos. Por tanto, aunque el modelo propuesto no es la estrategia más defensiva frente a pérdidas extremas, sí mantiene un comportamiento razonable dentro de la comparativa.

En cuanto a la parte operativa, el modelo presenta un *turnover* medio del 2.13 % y un coste total del 0.80 %, ya que el sistema realiza una gestión activa de cartera. Estos valores son superiores a los de *Equal Weight* y *Buy And Hold Index,* valores esperados ya que no generan ni rotación ni costes, al funcionar como estrategias de asignación fija. Además*, Inverse Volatility* también presenta mejores datos con un 0.63 % de *turnover* y un 0.24 % de coste total. Aun así, el modelo queda por debajo de estrategias más intensivas en rebalanceo, como *Mean Variance* y *Minimum Variance*, que alcanzan *turnovers* del 5.85 % y 2.97 %, respectivamente. Esto demuestra que el modelo no es la estrategia más costosa, pero sí mantiene un nivel de coste operativo moderado.

Estos resultados globales permiten resumir el comportamiento global del modelo final. **PPO_gated_full** no domina todas las métricas, pero mantiene una posición competitiva en comparación a las referencias clásicas y destaca por ofrecer un equilibrio entre

rentabilidad y control de riesgo. Sin embargo, la media global no permite ver en profundidad cómo se comporta cada estrategia en periodos completos. Por ello, en el siguiente apartado se analizan los resultados por ventanas temporales, con el objetivo de observar si el comportamiento del modelo se mantiene estable o cambia según las condiciones de mercado evaluadas.

## 5.4 Resultados por ventanas temporales

| Fold | Periodo test | Sharpe | CAGR | MaxDD | Calmar | CVaR | Turn. | Coste |
|---|---|---|---|---|---|---|---|---|
| 0 | 2017-12 -> 2018-12 | -0.132 | -2.29 | 22.68 | -0.101 | 48.13 | 1.34 | 0.50 |
| 1 | 2018-06 -> 2019-06 | 0.674 | 12.53 | 16.25 | 0.771 | 39.17 | 1.61 | 0.60 |
| 2 | 2018-12 -> 2019-12 | 2.051 | 31.09 | 5.96 | 5.215 | 28.85 | 2.19 | 0.82 |
| 3 | 2019-06 -> 2020-06 | 0.082 | -1.40 | 35.58 | -0.039 | 90.65 | 2.69 | 1.02 |
| 4 | 2019-12 -> 2020-12 | 0.439 | 11.81 | 34.85 | 0.339 | 89.16 | 2.16 | 0.82 |
| 5 | 2020-06 -> 2021-06 | 2.820 | 59.40 | 6.99 | 8.504 | 33.69 | 2.19 | 0.83 |
| 6 | 2020-12 -> 2021-12 | 2.239 | 37.31 | 6.36 | 5.869 | 31.35 | 2.36 | 0.89 |
| 7 | 2021-06 -> 2022-06 | -0.396 | -6.44 | 17.74 | -0.363 | 43.37 | 2.94 | 1.11 |
| 8 | 2021-12 -> 2022-12 | -0.019 | -0.46 | 16.64 | -0.027 | 45.03 | 2.21 | 0.83 |
| 9 | 2022-06 -> 2023-06 | 0.513 | 9.81 | 14.13 | 0.694 | 34.92 | 1.98 | 0.74 |
| 10 | 2022-12 -> 2023-12 | 1.429 | 20.91 | 11.47 | 1.823 | 23.69 | 2.72 | 1.02 |
| 11 | 2023-06 -> 2024-06 | 1.265 | 15.20 | 9.00 | 1.689 | 21.06 | 2.24 | 0.84 |
| 12 | 2023-12 -> 2024-12 | 1.904 | 23.23 | 3.98 | 5.836 | 21.80 | 1.07 | 0.40 |

***Tabla 5.4.*** *Resultados del modelo PPO_gated_full en las trece ventanas temporales de prueba del procedimiento walk-forward. Elaboración propia.*

La Tabla 5.4 muestra el resultado del modelo en cada ventana temporal de prueba. Esta tabla permite diseccionar cada resultado en situaciones distintas de mercado para realizar su análisis. Se observa que el modelo obtiene resultados muy favorables en algunas ventanas, con valores elevados, mientras que en otras aparecen métricas más débiles o incluso negativas. A continuación, se analizará la interpretación de estos datos, ya que cada ventana coincide con un contexto de mercado diferente. Por ello, este análisis permite entender mejor cuándo el modelo funciona con mayor solidez y en qué momentos encuentra más dificultades. Además, esta lectura será útil para compararlo posteriormente con las estrategias clásicas, ya que un resultado positivo o negativo del modelo puede interpretarse mejor al observar cómo se comportan las referencias en el mismo periodo.

En las primeras ventanas temporales, correspondientes al periodo 2017-2019, el modelo presenta resultados más desfavorables, especialmente en la ventana 0, donde el CAGR es negativo y el *Max Drawdown* alcanza el 22.68 %. Este comportamiento puede relacionarse con un entorno menos favorable para una estrategia dinámica, ya que 2018 estuvo marcado por correcciones bursátiles, mayor volatilidad, tensiones comerciales y dudas sobre la política de tipos de interés en Estados Unidos. Sin embargo, el comportamiento mejora en los periodos posteriores de esta misma etapa, especialmente durante la ventana 2. Este periodo coincide con la recuperación del mercado durante 2019, año en el que la renta variable estadounidense tuvo una recuperación importante tras las caídas de finales de 2018. En ese contexto, el modelo alcanza un Sharpe de 2.051, un

CAGR del 31.09 % y un Calmar de 5.215, con una caída máxima del 5.96 %. Estos resultados sugieren que, cuando el mercado presenta una dirección más clara y las condiciones son menos contradictorias, el modelo puede aprovechar mejor la información disponible para ajustar la cartera.

El siguiente tramo corresponde a las ventanas 3 y 4, que recogen el periodo asociado al shock inicial del COVID-19 y sus efectos inmediatos sobre los mercados. En estas ventanas, el modelo muestra caídas máximas muy elevadas, del 35.58 % y del 34.85 %, respectivamente. En la parte operativa, la ventana 3 presenta uno de los mayores niveles de *turnover*, con un 2.69 %, y un coste del 1.02 %. Esto puede explicarse por la necesidad del modelo de reajustar la cartera en un entorno de cambio muy rápido, donde las condiciones del mercado se modificaron de forma repentina. En la ventana 4, el *turnover* baja hasta el 2.16 % y el coste hasta el 0.82 %, lo que sugiere una operativa algo más contenida conforme el mercado empieza a asimilar el nuevo escenario. Este resultado es coherente con un entorno de fuerte incertidumbre, en el que las condiciones de mercado cambiaron de forma muy rápida y las señales recientes pudieron perder parte de su capacidad informativa. Aun así, un apunte interesante, es que se observa una diferencia entre ambas ventanas, mientras que en la ventana 3 el CAGR es negativo, en la ventana 4 vuelve a ser positivo, con un 11.81 %. Esto sugiere que el modelo sufrió durante el impacto inicial del shock, pero empezó a recuperar capacidad de ajuste conforme el mercado fue incorporando la nueva situación.

En las ventanas 5 y 6 se observa la fase más favorable para el modelo. Estas ventanas coinciden con la recuperación posterior al shock inicial del COVID-19, un periodo en el que el mercado mostró una dirección más clara y una fuerte recuperación de la renta variable. En este contexto, **PPO_gated_full** alcanza sus mejores resultados: en la ventana 5 obtiene un Sharpe de 2.820, un CAGR del 59.40 % y un Calmar de 8.504, mientras que en la ventana 6 mantiene también valores elevados, con un Sharpe de 2.239, un CAGR del 37.31 % y un Calmar de 5.869. Además, las caídas máximas se mantienen contenidas, en torno al 6-7 %. En estas ventanas, el *turnover* mantiene valores del 2.19 % y 2.36 %, y los costes se sitúan en 0.83 % y 0.89 %. Esto indica que el modelo sigue realizando ajustes activos, pero sin una rotación descontrolada. En este caso, los cambios en la cartera parecen haber sido útiles, porque se producen en una fase de mercado favorable y van acompañados de mayor crecimiento y caídas más reducidas. Estos resultados sugieren que el modelo funciona especialmente bien cuando el mercado presenta una tendencia más definida y las señales disponibles ofrecen una estructura más clara para ajustar la cartera.

En cambio, las ventanas 7 y 8 recogen una etapa más difícil para el modelo, asociada al entorno del año 2022. Una etapa marcada por el aumento de la inflación, las subidas de tipos de interés por parte de los bancos centrales y caídas importantes en los mercados de renta variable. En este contexto, las señales de mercado fueron menos estables y hubo una mayor presión en el entorno financiero, lo que pudo dificultar que la estrategia encontrara una dirección clara para ajustar la cartera. En estos periodos, el CAGR vuelve

a ser negativo o prácticamente nulo, y el Calmar también se sitúa por debajo de cero. En la parte operativa, la ventana 7 muestra además el mayor *turnover* de toda la tabla, con un 2.94 %, y un coste total del 1.11 %. Esto indica que el modelo intentó reajustar la cartera en un entorno complicado, pero esos cambios no fueron suficientes para evitar el deterioro del resultado. En la ventana 8, el *turnover* baja hasta el 2.21 % y el coste hasta el 0.83 %, aunque las métricas de rentabilidad siguen siendo débiles.

En las últimas ventanas se observa una recuperación progresiva del comportamiento del modelo tras la etapa más crítica de 2022. Los folds 9, 10 y 11 vuelven a presentar resultados positivos, aunque con distinta intensidad. En estas ventanas, el modelo recupera crecimiento y mantiene caídas máximas más contenidas que en los periodos anteriores, lo que sugiere una mejora progresiva conforme el entorno de mercado se estabiliza. La ventana 12 es la más destacada de esta fase, ya que combina un Sharpe elevado, un CAGR del 23.23 %, un Calmar de 5.836 y una caída máxima de solo el 3.98 %. Además, presenta el menor *turnover* de toda la tabla, con un 1.07 %, y el menor coste total, con un 0.40 %. Este resultado coincide con un entorno de mercado más favorable, con recuperación de la renta variable estadounidense tras la etapa complicada de 2022, menor presión inflacionaria y expectativas más favorables sobre la política monetaria.

En conjunto con estos datos, observamos que el modelo presenta sus mejores resultados donde el mercado presenta una dirección estable y las señales disponibles parecen ser coherentes. Sin embargo, muestra debilidades en etapas de cambios muy bruscos o mayor tensión financiera. Por ello, a continuación, se comparará el comportamiento del modelo con las estrategias clásicas de referencia, seleccionando los tres periodos más favorables y los tres más desfavorables para analizar si esos resultados se mantienen también en términos relativos.

### 5.4.1 Escenarios favorables

A continuación, para estudiar si los resultados absolutos del modelo también se mantienen en términos comparativos, se seleccionan tres ventanas en las que el modelo muestra un comportamiento especialmente competitivo frente a las estrategias clásicas de referencia. En concreto, se analizan las ventanas temporales 5, 12 y 6, ya que en estos periodos muestra un comportamiento muy positivo, tanto por la rentabilidad obtenida como por el control de las caídas y el nivel de operativa realizado.

**Fold 5 | Periodo: 2020-06 -> 2021-06**

| Estrategia | Sharpe | CAGR | MaxDD | Calmar | CVaR | Turn. | Coste |
|---|---|---|---|---|---|---|---|
| **PPO_gated_full** | **2.820** | **59.40** | **6.99** | **8.504** | 33.69 | 2.19 | 0.83 |
| EqualWeight | 2.707 | 52.94 | 7.81 | 6.775 | 34.58 | **0.00** | **0.00** |
| InvVolatility | 2.658 | 46.32 | 7.42 | 6.239 | 32.19 | 0.62 | 0.23 |
| Buy&Hold | 2.387 | 44.46 | 9.44 | 4.709 | 35.26 | **0.00** | **0.00** |
| MeanVariance | 1.168 | 25.08 | 10.32 | 2.432 | 45.03 | 4.91 | 1.86 |
| MinVariance | 1.369 | 20.45 | 8.55 | 2.391 | **29.03** | 1.74 | 0.66 |

***Tabla 5.5.*** *Comparación de estrategias en el fold 5, correspondiente al periodo 2020-06 a 2021-06. Elaboración propia.*

El periodo de la ventana 5 corresponde a la fase de recuperación posterior al shock inicial del COVID-19, un periodo en el que la renta variable recuperó fuerza y el mercado presentó una dirección más clara. En este contexto, el modelo obtiene un resultado sólido y supera a todas las estrategias clásicas en varias de las métricas principales. En concreto, alcanza el mejor Sharpe, el mayor CAGR, la menor caída máxima y el mejor ratio de Calmar de toda la comparativa. Este resultado es muy relevante porque muestra que, en esta ventana, el modelo no solo consigue aprovechar el crecimiento del mercado, sino que lo hace mejor que las referencias clásicas en términos de rentabilidad y control del *drawdown.*

La estrategia alcanza un CAGR del 59.40 %, por encima de *Equal Weight* e *Inverse Volatility*, y mantiene una caída máxima del 6.99 %, la más baja de la tabla. Como consecuencia, el Calmar alcanza un valor de 8.504, claramente superior al resto de estrategias. Esta combinación indica que el modelo consigue transformar un periodo de mercado favorable en una asignación de cartera muy eficiente, generando crecimiento elevado sin asumir una caída máxima proporcionalmente alta.

En cuanto al CVaR al 95%, el modelo no obtiene el mejor valor, ya que *Minimum Variance* presenta un resultado más defensivo. Aun así, **PPO_gated_full** se mantiene en niveles similares a *Equal Weight* e *Inverse Volatility* y mejora a *Buy & Hold* y *Mean Variance*. En la parte operativa, el modelo presenta más rotación que las estrategias pasivas y que *Inverse Volatility*, algo esperable al tratarse de una estrategia dinámica, pero queda claramente por debajo de *Mean Variance*. Esto indica que el buen resultado no se consigue mediante una rotación excesiva, sino mediante ajustes de cartera que parecen

haber sido útiles en una fase de mercado favorable. En conjunto, esta ventana muestra uno de los escenarios donde la propuesta aporta más valor frente a las referencias clásicas.

**Fold 12 | Periodo: 2023-12 -> 2024-12**

| Estrategia | Sharpe | CAGR | MaxDD | Calmar | CVaR | Turn. | Coste |
|---|---|---|---|---|---|---|---|
| **PPO_gated_full** | **1.904** | 23.23 | **3.98** | **5.836** | 21.80 | 1.07 | 0.40 |
| EqualWeight | 1.429 | 18.92 | 5.93 | 3.191 | 25.92 | **0.00** | **0.00** |
| InvVolatility | 1.457 | 17.15 | 5.67 | 3.027 | 22.69 | 0.66 | 0.25 |
| Buy&Hold | 1.679 | 24.92 | 8.41 | 2.964 | 29.93 | **0.00** | **0.00** |
| MeanVariance | 1.783 | **33.55** | 10.19 | 3.292 | 32.77 | 6.80 | 2.57 |
| MinVariance | 1.693 | 17.23 | 7.17 | 2.402 | **17.81** | 3.56 | 1.35 |

***Tabla 5.6.*** *Comparación de estrategias en el fold 12, correspondiente al periodo 2023-12 a 2024-12. Elaboración propia.*

En cuanto a la ventana 12, corresponde a una fase más reciente y favorable del mercado, en la que la renta variable estadounidense mantuvo una tendencia positiva tras la etapa más complicada de 2022. El modelo vuelve a mostrar un resultado especialmente sólido y obtiene el mejor Sharpe, la menor caída máxima y el mejor ratio de Calmar de toda la comparativa. Aunque *Mean Variance* alcanza el mayor CAGR, con un 33.55 %, lo hace asumiendo una caída máxima mucho mayor y con un coste operativo claramente superior. Por tanto, el modelo no lidera la rentabilidad aislada, pero sí ofrece una combinación más equilibrada entre crecimiento, control de caídas y eficiencia operativa.

Este resultado es especialmente relevante porque el modelo alcanza un CAGR del 23.23 % con una caída máxima de solo el 3.98 %, siendo la menor de la tabla. Como consecuencia, obtiene un Calmar de 5.836, claramente superior al resto de estrategias. Además, aunque no presenta el menor CVaR, se mantiene en un nivel competitivo frente a *Equal Weight*, *Inverse Volatility* y *Buy & Hold*. En la parte operativa, el modelo presenta un *turnover* del 1.07 % y un coste del 0.40 %, valores muy inferiores a los de *Mean Variance* y *Minimum Variance*. Esto indica que, en esta ventana, el modelo consigue buenos resultados sin depender de una rotación elevada, lo que refuerza la idea de una gestión dinámica pero contenida.

En conjunto, la ventana 12 muestra otro escenario en el que la propuesta aporta valor frente a las referencias clásicas. El modelo no supera a todas las estrategias en cada métrica individual, pero destaca en las métricas que relacionan rentabilidad y riesgo, especialmente Sharpe, MaxDD y Calmar.

***Tabla 5.7.*** *Comparación de estrategias en el fold 6, correspondiente al periodo 2020-12 a 2021-12. Elaboración propia.*

**Fold 6 | Periodo: 2020-12 -> 2021-12**

| Estrategia | Sharpe | CAGR | MaxDD | Calmar | CVaR | Turn. | Coste |
|---|---|---|---|---|---|---|---|
| **PPO_gated_full** | 2.239 | **37.31** | 6.36 | 5.869 | 31.35 | 2.36 | 0.89 |
| EqualWeight | 2.259 | 36.29 | **4.71** | **7.699** | 29.66 | **0.00** | **0.00** |
| InvVolatility | **2.264** | 32.60 | 4.83 | 6.757 | 27.83 | 0.62 | 0.23 |
| Buy&Hold | 1.982 | 30.82 | 5.11 | 6.026 | 29.07 | **0.00** | **0.00** |
| MeanVariance | 0.858 | 15.65 | 10.52 | 1.487 | 34.42 | 6.85 | 2.59 |
| MinVariance | 1.992 | 24.50 | 7.37 | 3.323 | **23.46** | 3.13 | 1.18 |

La ventana 6 también corresponde a la fase de recuperación posterior al COVID-19, aunque en este caso la comparación es más ajustada que en el periodo 5. **PPO_gated_full** obtiene el mayor CAGR de la tabla, con un 37.31 %. Sin embargo, no lidera el Sharpe ni el Calmar, donde *Equal Weight* e *Inverse Volatility* presentan valores ligeramente superiores. Esta lectura es interesante porque muestra que el modelo consigue capturar más crecimiento que las referencias, pero asumiendo una caída máxima algo mayor.

Aun así, el resultado sigue siendo muy positivo. El modelo alcanza un Sharpe de 2.239 y un Calmar de 5.869, valores elevados dentro de la comparativa, y mantiene una caída máxima del 6.36 %, claramente inferior a la de *Mean Variance* y *Minimum Variance*. En cuanto al CVaR, no obtiene el mejor resultado, ya que *Minimum Variance*, *Inverse Volatility* y *Buy & Hold* presentan valores más defensivos. Esto sugiere que, aunque el modelo logra una rentabilidad muy alta en esta ventana, no es la estrategia más conservadora frente a los peores resultados diarios.

En la parte operativa, el modelo presenta un turnover del 2.36 % y un coste del 0.89 %. Aunque estos valores son superiores a los de *Equal Weight*, *Buy & Hold* e *Inverse Volatility*, se mantienen por debajo de *Mean Variance* y *Minimum Variance*. Esto es positivo porque el modelo consigue el mayor CAGR de la comparativa sin que los costes se disparen. En otras palabras, ajusta la cartera de forma activa, pero mantiene una operativa razonable para el nivel de crecimiento que obtiene.

En conjunto, las ventanas más favorables del modelo muestran una idea común. **PPO_gated_full** obtiene sus mejores resultados cuando el entorno de mercado es más claro y no se producen cambios bruscos de régimen. En estos periodos, el modelo alcanza valores altos de Sharpe, CAGR y Calmar, pero además mantiene caídas y CVaR relativamente controlados. Esto es importante porque sugiere que los buenos resultados no proceden simplemente de asumir más riesgo. También destaca que este rendimiento se consigue con niveles de *turnover* y costes moderados, por lo que el modelo no necesita una rotación excesiva para obtener buenos resultados. En definitiva, estas comparativas indican que el diseño propuesto parece funcionar mejor cuando las señales de mercado y de contexto apuntan en una dirección coherente. Esto permite que la estrategia adapte la exposición de la cartera de forma eficiente y mantenga un equilibrio favorable entre rentabilidad, riesgo y operativa.

### 5.4.2 Escenarios desfavorables

A continuación, se analizan tres ventanas en las que **PPO_gated_full** presenta un comportamiento menos favorable frente a las estrategias clásicas de referencia: las ventanas 3, 4 y 7. El objetivo es estudiar en qué situaciones la propuesta pierde ventaja frente a las referencias y qué tipo de métricas explican esa diferencia.

**Fold 3 | Periodo: 2019-06 -> 2020-06**

| Estrategia | Sharpe | CAGR | MaxDD | Calmar | CVaR | Turn. | Coste |
|---|---|---|---|---|---|---|---|
| **PPO_gated_full** | 0.082 | -1.40 | 35.58 | -0.039 | 90.65 | 2.69 | 1.02 |
| EqualWeight | 0.381 | 9.60 | 35.27 | 0.272 | 92.83 | **0.00** | **0.00** |
| InvVolatility | 0.339 | 8.00 | 33.93 | 0.236 | 88.42 | 0.66 | 0.25 |
| Buy&Hold | 0.296 | 6.50 | 33.72 | 0.193 | 85.52 | **0.00** | **0.00** |
| MeanVariance | **0.586** | **15.83** | **27.37** | **0.578** | 72.81 | 5.49 | 2.07 |
| MinVariance | 0.209 | 4.05 | 28.04 | 0.145 | **70.02** | 3.31 | 1.25 |

***Tabla 5.8.*** *Comparación de estrategias en el fold 3, correspondiente al periodo 2019-06 a 2020-06. Elaboración propia.*

La ventana 3 recoge un periodo especialmente complejo, ya que incluye el inicio del shock del COVID-19 y las primeras caídas fuertes del mercado. **PPO_gated_full** queda por detrás de las estrategias clásicas en la mayoría de las métricas. El modelo obtiene un Sharpe de 0.082 y un CAGR negativo del -1.40 %, mientras que el resto de las estrategias consigue mantener rentabilidades positivas. Además, su MaxDD alcanza el 35.58 % y el Calmar se sitúa ligeramente por debajo de cero. Esto indica que, en una fase de cambio tan brusco, el modelo tuvo dificultades para ajustar la cartera de forma suficientemente rápida y eficaz.

En esta ventana destaca especialmente *Mean Variance*, que obtiene el mejor Sharpe, el mayor CAGR, el menor MaxDD y el mejor Calmar. Esto muestra que, en este tramo concreto, una estrategia clásica de optimización consiguió responder mejor que el modelo dinámico. En cambio, el modelo realizó ajustes en la cartera, pero no logró convertir esa gestión en una mejora del rendimiento. De hecho, presenta un *turnover* del 2.69 % y un coste del 1.02 %, valores superiores a los de las estrategias más estables, aunque inferiores a los de *Mean Variance* y *Minimum Variance.*

En conclusión, esta ventana muestra una situación en la que la propuesta pierde ventaja frente a las referencias. Los datos observados presentan que puede tener más dificultades cuando el mercado cambia de forma repentina y las señales disponibles se vuelven menos claras. En este tipo de entorno, la gestión dinámica no siempre se traduce en mejores resultados, especialmente si los reajustes llegan tarde o no consiguen compensar la velocidad del movimiento del mercado.

**Fold 4 | Periodo: 2019-12 -> 2020-12**

| Estrategia | Sharpe | CAGR | MaxDD | Calmar | CVaR | Turn. | Coste |
|---|---|---|---|---|---|---|---|
| **PPO_gated_full** | 0.439 | 11.81 | 34.85 | 0.339 | 89.16 | 2.16 | 0.82 |
| EqualWeight | 0.735 | 24.88 | 35.27 | 0.705 | 92.90 | **0.00** | **0.00** |
| InvVolatility | 0.696 | 22.32 | 33.93 | 0.658 | 88.50 | 0.70 | 0.27 |
| Buy&Hold | 0.585 | 17.22 | 33.72 | 0.511 | 86.48 | **0.00** | **0.00** |
| MeanVariance | **0.931** | **29.89** | **27.37** | **1.092** | 81.23 | 4.28 | 1.62 |
| MinVariance | 0.291 | 6.39 | 28.04 | 0.228 | **71.52** | 2.39 | 0.91 |

***Tabla 5.9.*** *Comparación de estrategias en el fold 4, correspondiente al periodo 2019-12 a 2020-12. Elaboración propia.*

La ventana 4 también está asociada al impacto del COVID-19, aunque recoge un periodo algo más amplio que incluye tanto la caída inicial como parte de la recuperación posterior. En este caso, el modelo mejora respecto a la ventana anterior, ya que vuelve a obtener un CAGR positivo del 11,81 %. Sin embargo, sigue quedando por detrás de varias estrategias clásicas en métricas como Sharpe, CAGR y Calmar.

Aun así, el comportamiento del modelo no es completamente negativo. Aunque su MaxDD sigue siendo elevado, con un 34.85 %, se sitúa muy cerca de *Equal Weight* y mejora ligeramente su caída máxima. Además, el modelo obtiene un CVaR inferior al de *Equal Weight*, lo que indica un comportamiento algo menos desfavorable en los peores resultados diarios frente a esa referencia.

En conjunto, esta ventana muestra una mejora parcial respecto a la ventana 3, pero no suficiente para situar al modelo por delante de las principales referencias. El resultado es coherente con un periodo todavía marcado por una elevada incertidumbre, donde las condiciones cambiaron con rapidez y las estrategias más simples o clásicas lograron capturar mejor la recuperación posterior.

**Fold 7 | Periodo: 2021-06 -> 2022-06**

| Estrategia | Sharpe | CAGR | MaxDD | Calmar | CVaR | Turn. | Coste |
|---|---|---|---|---|---|---|---|
| **PPO_gated_full** | -0.396 | -6.44 | 17.74 | -0.363 | 43.37 | 2.94 | 1.11 |
| EqualWeight | -0.210 | -3.59 | 17.76 | -0.202 | 46.10 | **0.00** | **0.00** |
| InvVolatility | -0.080 | -0.69 | 15.67 | -0.044 | 41.33 | 0.62 | 0.23 |
| Buy&Hold | -0.560 | -10.50 | 23.01 | -0.456 | 48.89 | **0.00** | **0.00** |
| MeanVariance | -0.242 | -4.26 | 20.58 | -0.207 | 46.16 | 7.11 | 2.69 |
| MinVariance | **0.192** | **3.70** | **14.53** | **0.255** | **31.03** | 3.98 | 1.51 |

***Tabla 5.10****. Comparación de estrategias en el fold 7, correspondiente al periodo 2021-06 a 2022-06. Elaboración propia.*

La ventana 7 recoge otro periodo especialmente complicado para el modelo, asociado al entorno de 2022. En este contexto, el modelo obtiene un Sharpe negativo de -0.396 y un CAGR del -6.44 %, por lo que queda por detrás de varias estrategias de referencia. Destaca especialmente *Minimum Variance*, que es la única estrategia que mantiene rentabilidad positiva en esta ventana y además obtiene el mejor Sharpe, el menor *MaxDD* y el mejor Calmar.

Aun así, el resultado del modelo no debe interpretarse solo desde la rentabilidad. La estrategia propuesta consigue una caída máxima del 17.74 %, claramente inferior a la de *Buy & Hold*, que alcanza el 23.01 %. Esto indica que, aunque el modelo no logra evitar una rentabilidad negativa, sí contiene mejor la caída que una exposición pasiva al mercado. Sin embargo, frente a estrategias más defensivas como *Minimum Variance* e *Inverse Volatility*, el modelo queda peor posicionado, tanto en *drawdown* como en CVaR.

En la parte operativa, el modelo presenta un *turnover* del 2.94 % y un coste del 1.11 %. Estos valores muestran que la estrategia intentó reajustar la cartera en un entorno difícil, pero esos cambios no fueron suficientes para recuperar el rendimiento.

En conclusión, estas ventanas muestran los contextos en los que el modelo pierde más ventaja frente a las referencias clásicas. En ellas, **PPO_gated_full** presenta peores valores de Sharpe, CAGR y Calmar, junto con caídas y CVaR más elevados. Esto sugiere que el modelo tiene más dificultades cuando el mercado cambia con rapidez, las señales son menos claras o el entorno financiero está sometido a mayor tensión. Además, aunque la estrategia sigue reajustando la cartera, ese mayor nivel de actividad no siempre se traduce en mejores resultados. Por tanto, la principal limitación observada es que la capacidad de adaptación del modelo puede verse reducida en periodos de ruptura brusca o de alta incertidumbre, donde las referencias más defensivas o estables pueden comportarse mejor.

## 5.5 Discusión de los resultados

Los resultados obtenidos muestran que **PPO_gated_full** no domina de forma absoluta a todas las estrategias clásicas en todas las métricas. *Equal Weight* e *Inverse Volatility* siguen siendo referencias muy competitivas, especialmente en términos de Sharpe y CAGR. Sin embargo, el modelo final destaca por ofrecer un perfil equilibrado entre rentabilidad, control de caídas y operativa. Esta lectura se refleja especialmente en el ratio de Calmar global, donde obtiene el mejor valor de la comparativa.

El buen resultado del modelo en el ratio de Calmar sugiere que su ventaja se encuentra en encontrar una relación favorable entre crecimiento y *drawdown.* Por ello, el modelo no solo crece, sino que lo hace sin deteriorar excesivamente la cartera en los peores momentos. Esta idea encaja con el planteamiento del modelo, ya que el agente ajusta la cartera de una forma gradual, penaliza las pérdidas y el aumento de las caídas acumuladas de cartera.

Esta lectura es importante porque el sistema no está planteado solo para maximizar la rentabilidad anual, sino para aprender una política de asignación dinámica que también tenga en cuenta el riesgo, las restricciones y los costes de operar. Desde esta perspectiva, el modelo muestra que puede competir con enfoques clásicos sin depender de una asignación fija y que, en determinados periodos, es capaz de aprovechar la información de mercado y de contexto para ajustar la cartera de forma eficaz.

En las ventanas donde el modelo obtiene mejores resultados, parece existir un entorno más fácil de interpretar para la política aprendida. Es decir, los movimientos recientes de los activos, la tendencia del mercado y las variables externas ofrecen una información más alineada entre sí. En esas condiciones, el modelo puede ajustar la cartera con mayor claridad, aumentando o reduciendo exposición de forma más acertada y manteniendo un equilibrio favorable entre crecimiento y riesgo. Esto ocurre especialmente durante la recuperación posterior al shock inicial del COVID-19 y en la fase favorable de 2023-2024. Estos escenarios tienen en común que la información de mercado y su contexto macro financiero parecen aportar una señal más clara y útil para ajustar los cambios de la cartera, lo que le permite al agente capturar el crecimiento del mercado.

En otros periodos, la situación es distinta. Cuando el mercado cambia de forma repentina o aparecen episodios de mayor incertidumbre, las señales que recibe el modelo pueden perder claridad o incluso apuntar en direcciones distintas. En esos casos, reajustar la cartera no siempre basta para mejorar el resultado, porque la información disponible es menos estable y las decisiones pueden volverse menos precisas. Esto ayuda a entender por qué el modelo no mantiene la misma ventaja en todas las ventanas, especialmente en aquellas donde aumenta la rotación sin que mejore el rendimiento. Esto se observa en el inicio de la crisis del COVID-19 y en el periodo de 2022, momentos de incertidumbre y estrés económico, lo que provoca que el reajuste dinámico de la cartera no siempre consiga anticipar o compensar el deterioro del mercado.

La parte operativa también ayuda a interpretar los resultados del modelo. Los niveles de *turnover* y coste se mantienen en un rango razonable y no alcanzan los valores de las estrategias más intensivas en rebalanceo. Esto indica que el modelo no obtiene sus resultados simplemente cambiando la cartera de forma constante, sino que mantiene una gestión activa pero controlada. Esto encaja con los mecanismos de seguridad y control incorporados en la arquitectura.

Este análisis de resultados sugiere que el modelo funciona mejor cuando encuentra coherencia entre la tendencia del mercado, las variables financieras recientes y el contexto macroeconómico. En esos casos, el mecanismo de *gating* ayuda a que el modelo aproveche mejor el contexto externo, ya que permite modular su influencia según la utilidad que pueda tener en cada momento. Así, la política no toma decisiones únicamente con los datos internos de activos, sino también con una señal contextual filtrada según su utilidad. Por el contrario, en cambios rápidos de régimen o ante shocks repentinos, la información disponible puede ser menos fiable y el modelo pierde parte de su ventaja frente a las estrategias más simples.

Para concluir, los resultados muestran que un modelo de aprendizaje por refuerzo con contexto exógeno y mecanismos de control puede ser una alternativa competitiva para la asignación dinámica de carteras. Aun así, su comportamiento no es el mismo en todos los periodos y depende del contexto de mercado. Por ello, la aportación principal del modelo no debe entenderse como una superioridad absoluta frente a todas las estrategias clásicas,

sino como una propuesta capaz de combinar adaptación, control del riesgo y estabilidad operativa en distintos escenarios.

# Capítulo 6. Conclusiones y trabajo futuro

## 6.1 Conclusiones

Este trabajo ha permitido desarrollar y evaluar una propuesta completa para la optimización dinámica de carteras mediante aprendizaje por refuerzo profundo. A partir del modelo final implementado, se ha comprobado que este tipo de enfoque puede aplicarse al problema de asignación de activos incorporando no solo información histórica de mercado, sino también variables externas y mecanismos de control del riesgo.

Una de las principales conclusiones es que el modelo propuesto no debe entenderse como una estrategia que sustituye de forma directa a los métodos clásicos, sino como una alternativa dinámica que puede resultar competitiva en distintos contextos. Las estrategias tradicionales siguen siendo referencias difíciles de superar, sobre todo cuando el mercado favorece asignaciones diversificadas y estables. Aun así, los resultados muestran que el modelo puede aportar valor cuando la evaluación no se limita a la rentabilidad, sino que también considera el riesgo, las caídas y la parte operativa.

La evaluación realizada también confirma la importancia de analizar los resultados por ventanas temporales. La media global ofrece una primera lectura, pero no refleja por completo cómo cambia el comportamiento del modelo entre periodos. En algunas ventanas, la estrategia aprovecha mejor las señales disponibles y consigue una buena relación entre crecimiento y control de caídas. En otras, especialmente cuando el entorno cambia de forma brusca o las señales son menos claras, su ventaja frente a las referencias se reduce.

En relación con los objetivos planteados al inicio del trabajo, puede considerarse que se han cumplido de forma satisfactoria. A lo largo del proyecto se ha diseñado, implementado y evaluado un sistema completo de asignación dinámica de carteras basado en aprendizaje por refuerzo profundo. El modelo incorpora variables de mercado, contexto exógeno y mecanismos de control, y se ha comparado con distintas estrategias clásicas mediante un esquema *walk-forward*. Aunque los resultados no muestran una superioridad absoluta frente a todos los métodos comparados, sí permiten comprobar que la propuesta es competitiva y que aporta valor cuando la evaluación tiene en cuenta no solo la rentabilidad, sino también el riesgo y la operativa.

## 6.2 Limitaciones

La primera limitación del trabajo está relacionada con el universo de inversión utilizado. La evaluación se realiza sobre 100 activos del S&P 500, por lo que los resultados obtenidos no garantizan que el modelo tenga el mismo comportamiento en otros mercados, países, sectores o universos de activos. Además, al trabajar con una selección fija de compañías, puede existir cierto sesgo de supervivencia. Este sesgo aparece cuando el análisis incluye únicamente activos que han permanecido disponibles durante todo el

periodo, dejando fuera empresas que salieron del índice, dejaron de cotizar o tuvieron un peor comportamiento. Como consecuencia, el universo evaluado puede resultar más favorable de lo que habría sido en una situación real, donde el inversor no conoce de antemano qué empresas permanecerán en el mercado.

Otra limitación está relacionada con la forma en que se evalúa el modelo. Aunque el esquema *walk-forward* respeta el orden temporal de los datos y resulta más realista que una división aleatoria, la evaluación sigue siendo un *backtesting* sobre datos históricos. Por tanto, no equivale a una prueba en tiempo real ni recoge todos los factores que podrían aparecer en una ejecución real de mercado. Además, los costes de transacción y el *slippage* se han definido mediante valores fijos, cuando en la práctica pueden variar según la liquidez de cada activo, el volumen negociado o el momento de ejecución.

También debe tenerse en cuenta que el modelo depende de la calidad de los datos y de las decisiones de diseño adoptadas. El estado del agente se construye a partir de datos de mercado y variables macro financieras externas, por lo que posibles errores, datos ausentes, revisiones de series o desfases temporales podrían afectar a la información disponible para tomar decisiones. Además, los resultados pueden variar según decisiones como la longitud de las ventanas *walk-forward*, la función de recompensa, los costes asumidos, el número de activos, la frecuencia diaria, entre otros. Por ello, los resultados deben interpretarse dentro del marco experimental definido en este trabajo.

## 6.3 Trabajo futuro

Una primera línea de trabajo futuro sería enriquecer el estado observado por el agente con nuevas fuentes de información externa. En este trabajo se han incorporado variables de mercado y contexto macro financiero, pero podrían añadirse señales de sentimiento, noticias financieras, indicadores de incertidumbre, datos de analistas o información sectorial. Este tipo de variables podría ayudar al modelo a interpretar mejores cambios de mercado que no siempre aparecen de forma inmediata en los precios o el volumen. Además, disponer de un estado más rico podría mejorar la respuesta del sistema en episodios de caídas bruscas o cambios rápidos de régimen, donde en este trabajo se ha observado que el modelo encuentra más dificultades.

Otra línea de trabajo futuro sería probar el modelo en otros universos de inversión. En este trabajo la evaluación se ha realizado sobre 100 activos del S&P 500, por lo que sería interesante comprobar si los resultados se mantienen en otros índices, mercados internacionales, sectores concretos o incluso en otros tipos de activos. Esto permitiría valorar mejor hasta qué punto el modelo puede generalizarse más allá del universo utilizado en los experimentos.

También sería útil hacer que la simulación se acerque más a una operativa real. En este trabajo, los costes de transacción y el *slippage* se han representado mediante valores fijos, pero en la práctica estos costes pueden cambiar según el activo, la liquidez disponible, el volumen negociado o el momento de mercado. Incorporar estos elementos permitiría

comprobar con más precisión si la estrategia seguiría siendo viable en condiciones más parecidas a las de una ejecución real.

Por último, sería interesante mejorar la interpretabilidad del modelo. Aunque las métricas permiten evaluar su rendimiento global y por ventanas, todavía no siempre es fácil entender por qué el agente cambia determinados pesos en un momento concreto. En futuras versiones, podrían incorporarse herramientas que ayuden a ver qué variables influyen más en sus decisiones, cómo utiliza el mecanismo de *gating* y cómo se relacionan los cambios de la cartera con el contexto de mercado. Esto permitiría comprender mejor el comportamiento del modelo.

En definitiva, este trabajo muestra que la aplicación del aprendizaje por refuerzo profundo a la optimización de carteras puede ser una vía prometedora cuando se combina con información externa y mecanismos de control del riesgo. Aunque los resultados no permiten afirmar una superioridad absoluta frente a todas las estrategias clásicas, sí muestran que el modelo propuesto puede ofrecer un comportamiento competitivo y equilibrado en distintos escenarios. Por tanto, la propuesta desarrollada constituye una base sólida sobre la que seguir avanzando hacia sistemas de inversión más adaptativos, interpretables y cercanos a las condiciones reales de mercado.

# Bibliografía

Avellaneda, M., & Lee, J.-H. (2010). Statistical arbitrage in the US equities market. *Quantitative Finance, 10*(7), 761–782. https://doi.org/10.1080/14697680903124632

Bai, Y., Gao, Y., Wan, R., Zhang, S., & Song, R. (2025). A review of reinforcement learning in financial applications. *Annual Review of Statistics and Its Application, 12*, 209–232. https://doi.org/10.1146/annurev-statistics-112723-034423

Buckley, I., Saunders, D., & Seco, L. (2008). Portfolio optimization when asset returns have the Gaussian mixture distribution. *European Journal of Operational Research, 185(3)*, 1434–1461. https://doi.org/10.1016/j.ejor.2005.03.080

Choudhary, H., Orra, A., Sahoo, K., & Thakur, M. (2025). Risk-adjusted deep reinforcement learning for portfolio optimization: *A multi-reward approach. International Journal of Computational Intelligence Systems, 18(1)*, 126. https://doi.org/10.1007/s44196-025-00875-8

DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies, 22(5)*, 1915–1953. https://doi.org/10.1093/rfs/hhm075

Diamond, S., & Boyd, S. (2016). CVXPY: A Python-embedded modeling language for convex optimization. *Journal of Machine Learning Research, 17(83)*, 1–5. https://jmlr.org/papers/v17/15-408.html

Espiga-Fernández, F., García-Sánchez, Á., & Ordieres-Meré, J. (2024). A systematic approach to portfolio optimization: A comparative study of reinforcement learning agents, market signals, and investment horizons. *Algorithms, 17(12),* 570. https://doi.org/10.3390/a17120570

European Parliament and Council. (2009). *Directive 2009/65/EC on the coordination of laws, regulations and administrative provisions relating to undertakings for collective investment in transferable securities (UCITS)*. Official Journal of the European Union.

European Securities and Markets Authority. (s. f.). *Article 52 – UCITS Directive: Investment limits*. ESMA Interactive Single Rulebook.

Fujimoto, S., van Hoof, H., & Meger, D. (2018). Addressing function approximation error in actor-critic methods. *Proceedings of Machine Learning Research, 80*, 1587–1596. https://proceedings.mlr.press/v80/fujimoto18a.html

Gu, F., Stefanidis, A., García-Fernández, Á., Su, J., & Li, H. (2025). *MIGT: Memory instance gated transformer framework for financial portfolio management.* arXiv. https://doi.org/10.48550/arXiv.2502.07280

Haarnoja, T., Zhou, A., Hartikainen, K., Tucker, G., Ha, S., Tan, J., Kumar, V., Zhu, H., Gupta, A., Abbeel, P., & Levine, S. (2018). *Soft actor-critic algorithms and applications*. arXiv. https://doi.org/10.48550/arXiv.1812.05905

Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. *In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 7132–7141). https://doi.org/10.1109/CVPR.2018.00745

Jiang, Z., Xu, D., & Liang, J. (2017). *A deep reinforcement learning framework for the financial portfolio management problem*. arXiv. https://doi.org/10.48550/arXiv.1706.10059

Jin, O., & El-Saawy, H. (2016). *Portfolio management using reinforcement learning*. Stanford University.

Lillicrap, T. P., Hunt, J. J., Pritzel, A., Heess, N., Erez, T., Tassa, Y., Silver, D., & Wierstra, D. (2015). *Continuous control with deep reinforcement learning*. arXiv. https://doi.org/10.48550/arXiv.1509.02971

Liu, X.-Y., Xia, Z., Rui, J., Gao, J., Yang, H., Zhu, M., Wang, C. D., Wang, Z., & Guo, J. (2022). *FinRL-Meta: Market environments and benchmarks for data-driven financial reinforcement learning*. arXiv. https://doi.org/10.48550/arXiv.2211.03107

López de Prado, M. (2018). *Advances in financial machine learning. John Wiley & Sons.*

*Mantshimuli, L. A., & Mwamba, J. W. M. (2026). Toward a unified agentic framework for regime-aware portfolio optimization with LLM signals. International Journal of Data Science and Analytics. https://doi.org/10.1007/s41060-026-01066-0*

Markowitz, H. (1952). Portfolio selection. *The Journal of Finance, 7(1)*, 77–91. https://doi.org/10.1111/j.1540-6261.1952.tb01525.x

Michaud, R. O. (1989). The Markowitz optimization enigma: Is "optimized" optimal? *Financial Analysts Journal, 45(1),* 31–42. https://doi.org/10.2469/faj.v45.n1.31

Montero García, L. (2026). *Gated PPO portfolio optimization* (Versión v1.0-tfg) [Código fuente]. GitHub. https://github.com/lmg136-ua/gated-ppo-portfolio-optimization

Oliveira, D. C., Sandfelder, D., Fujita, A., Dong, X., & Cucuringu, M. (2025*). Tactical asset allocation with macroeconomic regime detection*. arXiv. https://doi.org/10.48550/arXiv.2503.11499

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J., & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep

learning library. *Advances in Neural Information Processing Systems, 32*. https://proceedings.neurips.cc/paper/2019/hash/bdbca288fee7f92f2bfa9f7012727740-Abstract.html

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12(85)*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Perez, E., Strub, F., de Vries, H., Dumoulin, V., & Courville, A. (2018). FiLM: Visual reasoning with a general conditioning layer. *Proceedings of the AAAI Conference on Artificial Intelligence, 32(1).* https://doi.org/10.1609/aaai.v32i1.11671

Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., & Dormann, N. (2021). Stable-Baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research, 22(268*), 1–8. https://jmlr.org/papers/v22/20-1364.html

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017*). Proximal policy optimization algorithms.* arXiv. https://doi.org/10.48550/arXiv.1707.06347

Stanciu, M. M. (2022). *Artificial intelligence-driven systems for financial forecasting* [Doctoral dissertation, University of Cagliari].

Stellato, B., Banjac, G., Goulart, P., Bemporad, A., & Boyd, S. (2020). OSQP: An operator splitting solver for quadratic programs. *Mathematical Programming Computation, 12(4),* 637–672. https://doi.org/10.1007/s12532-020-00179-2

Sun, S., Qin, M., Zhang, W., Xia, H., Zong, C., Ying, J., Xie, Y., Zhao, L., Wang, X., & An, B. (2023). TradeMaster: A holistic quantitative trading platform empowered by reinforcement learning. *Advances in Neural Information Processing Systems, 36,* 59047–59061. https://proceedings.neurips.cc/paper_files/paper/2023/hash/b8f6f7f2ba4137124ac976286eacb611-Abstract-Datasets_and_Benchmarks.html

Wachi, A., Shen, X., & Sui, Y. (2024). A survey of constraint formulations in safe reinforcement learning. *In Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence* (pp. 8262–8271). https://doi.org/10.24963/ijcai.2024/913

Wang, X., & Liu, L. (2025). Risk-sensitive deep reinforcement learning for portfolio optimization. *Journal of Risk and Financial Management, 18(7),* 347. https://doi.org/10.3390/jrfm18070347

Woo, S., Park, J., Lee, J.-Y., & Kweon, I. S. (2018). CBAM: Convolutional block attention module. In *Proceedings of the European Conference on Computer Vision (ECCV)* (pp. 3–19). https://doi.org/10.1007/978-3-030-01234-2_1

Xue, P., & Ye, Y. (2026). Attention-enhanced reinforcement learning for dynamic portfolio optimization. *Intelligent Systems with Applications, 29*, 200622. https://doi.org/10.1016/j.iswa.2025.200622

Yang, S. (2023). Deep reinforcement learning for portfolio management. *Knowledge-Based Systems, 278*, 110905. https://doi.org/10.1016/j.knosys.2023.110905

Ye, Y., Pei, H., Wang, B., Chen, P.-Y., Zhu, Y., Xiao, J., & Li, B. (2020). Reinforcement-learning based portfolio management with augmented asset movement prediction states. *Proceedings of the AAAI Conference on Artificial Intelligence, 34(1)*, 1229–1237. https://doi.org/10.1609/aaai.v34i01.5462